

ĐẠI HỌC BÁCH KHOA HÀ NỘI

ĐỒ ÁN TỐT NGHIỆP

Mô hình Meta-learning tối ưu vận hành hệ thống điện

NGUYỄN TẤT CƯỜNG

cuong.nt227090@sis.hust.edu.vn

Chuyên ngành: Toán Tin

Giảng viên hướng dẫn : TS. Trần Ngọc Thắng

Bộ môn : Toán Tin

Khoa : Khoa Toán Tin

Chữ ký GVHD

Hà Nội, 06-2026

NHẬN XÉT CỦA GIẢNG VIÊN HƯỚNG DẪN ĐỒ ÁN II

1. Thông tin sinh viên :

Họ và tên : Nguyễn Tất Cường. Lớp : MI1 - K67

Thời gian thực hiện : 09/03/2026 - 21/06/2026.

2. Mục tiêu và nội dung của Đồ án :

Đồ án tập trung nghiên cứu ứng dụng Meta-learning trong tối ưu hóa vận hành hệ thống điện, nhằm nâng cao khả năng thích ứng và hiệu quả của các mô hình điều độ kinh tế khi đối mặt với sự biến động mạnh của phụ tải và nguồn năng lượng tái tạo.

3. Lời cam kết của sinh viên :

Em xin cam kết rằng đồ án này do em tự thực hiện, dưới sự hướng dẫn khoa học của Thầy TS. Trần Ngọc Thăng. Các kết quả nghiên cứu, số liệu và nội dung trình bày trong đồ án là trung thực. Mọi tài liệu, số liệu và kết quả nghiên cứu của các tác giả khác được sử dụng trong đồ án đều đã được trích dẫn đầy đủ, rõ ràng và đúng quy định. Em xin hoàn toàn chịu trách nhiệm trước nhà trường và khoa về lời cam kết này.

Hà Nội, ngày tháng năm 2026
Tác giả

Nguyễn Tất Cường

4. Xác nhận của Giảng viên hướng dẫn:

.....

Hà Nội, ngày tháng năm 2025
Giảng viên hướng dẫn

TS. Trần Ngọc Thăng

Lời cảm ơn

Em xin chân thành cảm ơn **TS. Trần Ngọc Thắng** đã tận tình hướng dẫn, chỉ bảo và tạo điều kiện thuận lợi cho em trong suốt quá trình thực hiện đề án này. Những góp ý quý báu của các thầy đã giúp em hoàn thiện nghiên cứu và nâng cao chất lượng đề án.

Em cũng xin gửi lời cảm ơn sâu sắc đến các đồng nghiệp tại **Trung tâm kinh tế môi trường và biến đổi khí hậu (CECCS) - Liên hiệp các Hội Khoa học và Kỹ thuật Việt Nam (VUSTA)** đã luôn đồng hành, hỗ trợ và chia sẻ kinh nghiệm quý báu trong suốt thời gian thực hiện đề án. Sự giúp đỡ nhiệt tình của mọi người đã tạo động lực to lớn giúp em vượt qua những khó khăn và hoàn thành tốt đề án này.

Cuối cùng, em xin cảm ơn **gia đình, bạn bè** đã luôn động viên, ủng hộ và tạo điều kiện tốt nhất để em có thể hoàn thành chương trình học tập.

Hà Nội, tháng năm 2026
Tác giả đề án

Nguyễn Tất Cường

Mục lục

DANH SÁCH HÌNH VẼ	iii
DANH SÁCH BẢNG	iv
TÓM TẮT NỘI DUNG ĐỒ ÁN	v
1 GIỚI THIỆU	1
1.1 Bối cảnh và tầm quan trọng của đề tài	1
1.2 Mục tiêu nghiên cứu	2
1.3 Phạm vi nghiên cứu	3
2 CƠ SỞ LÝ THUYẾT	4
2.1 Bài toán Quy hoạch mở rộng nguồn điện (GEP)	4
2.1.1 Định nghĩa bài toán	4
2.1.2 Phân loại các phương pháp giải GEP	5
2.2 Tối ưu hóa hai tầng (Bi-level Optimization)	5
2.2.1 Khái niệm và phát biểu toán học	5
2.2.2 Đặc điểm của bài toán bi-level	6
2.3 Quy hoạch tuyến tính (Linear Programming)	6
2.3.1 Lý thuyết cơ bản	6
2.3.2 Thuật toán giải LP	7
2.3.3 Bài toán Điều độ kinh tế (Economic Dispatch)	7
2.4 Tối ưu hóa Bayes (Bayesian Optimization)	8
2.4.1 Khái niệm và động lực	8
2.4.2 Các thành phần cốt lõi	9
2.4.3 Quy trình tối ưu hóa Bayes	10
2.5 Quá trình quyết định Markov (MDP)	10
2.5.1 Định nghĩa	10
2.5.2 Chính sách và hàm giá trị	11
2.6 Học tăng cường (Reinforcement Learning)	12
2.6.1 Tổng quan	12
2.6.2 Phương pháp Policy Gradient	12
2.6.3 PPO – Proximal Policy Optimization	12
2.6.4 SAC – Soft Actor-Critic	13
2.7 Chi phí đầu tư niên kim hóa (Annualized CAPEX)	14
2.7.1 Nhân tử thu hồi vốn (Capital Recovery Factor)	14
2.8 Phân tích kịch bản ngẫu nhiên (Stochastic Scenario Analysis)	15

2.8.1	Mô phỏng Monte Carlo	15
2.8.2	Liên hệ với đề tài	17
2.9	Tổng kết chương	18
3	MÔ HÌNH HÓA BÀI TOÁN QUY HOẠCH MỞ RỘNG NGUỒN ĐIỆN	20
3.1	Khung mô hình tối ưu hóa lai hai tầng	20
3.2	Mô hình toán học tầng dưới cho bài toán điều độ kinh tế .	21
3.2.1	Tập hợp, tham số và biến quyết định	21
3.2.2	Hàm mục tiêu và hệ ràng buộc	23
3.3	Mô hình toán học tầng trên cho bài toán quy hoạch mở rộng nguồn điện	24
3.3.1	Biến quyết định của bài toán đầu tư	24
3.3.2	Hàm mục tiêu tổng quát của tầng trên	24
3.4	Mô hình hóa tính bất định thông qua phân tích kịch bản Monte Carlo	25
4	PHƯƠNG PHÁP GIẢI BÀI TOÁN	26
4.1	Phương pháp giải bài toán tối ưu hộp đen ở tầng trên . . .	26
4.1.1	Tối ưu hóa Bayes (Bayesian Optimization - BO) . .	26
4.1.2	Học tăng cường (Reinforcement Learning - RL) . .	27
4.2	Đặc tả môi trường tương tác cho bài toán học tăng cường	28
4.2.1	Không gian quan sát	28
4.2.2	Không gian hành động và cơ chế phần thưởng . . .	28
4.3	Thiết kế hệ thống và quy trình triển khai tính toán	29
5	KẾT QUẢ THỰC NGHIỆM VÀ THẢO LUẬN	31
5.1	Thiết lập và tiêu chí đánh giá	31
5.2	So sánh định lượng giữa các kịch bản	32
5.3	Phân tích cơ cấu đầu tư tối ưu	33
5.4	Hành vi hội tụ của Bayesian Optimization	34
	TÀI LIỆU THAM KHẢO	35

Danh sách hình vẽ

3.1. Sơ đồ luồng thông tin trong kiến trúc tối ưu hóa lai hai tầng	21
5.3. Phân bổ công suất đầu tư tối ưu theo vùng và công nghệ cho ba kịch bản cần mở rộng nguồn.	33
5.4. Đường hội tụ của Bayesian Optimization cho hai kịch bản tiêu biểu.	34

Danh sách bảng

2.9. Tóm tắt vai trò của các lý thuyết trong hệ thống bi-level. .	19
5.2.1 So sánh baseline và phương án tối ưu Bayesian trên bốn kịch bản. Giá trị hàm phạt được chuẩn hóa theo tỷ USD, còn cắt tải được quy đổi về GWh.	32

Tóm tắt nội dung đề án

Bài toán Quy hoạch mở rộng nguồn điện (Generation Expansion Planning - GEP) đóng vai trò then chốt trong việc đảm bảo an ninh năng lượng và tối ưu hóa chi phí đầu tư hệ thống điện. Các phương pháp truyền thống dựa trên Quy hoạch tuyến tính nguyên hỗn hợp (MILP) thường đối mặt với thách thức về tốc độ tính toán khi mở rộng quy mô, trong khi các mô hình Học tăng cường (RL) thuần túy lại khó đảm bảo các ràng buộc vật lý khắt khe của hệ thống.

Đề tài này đề xuất một kiến trúc tối ưu hóa lai hai tầng (Bi-level Hybrid Optimization) nhằm kết hợp ưu điểm của cả hai cách tiếp cận. Tầng trên sử dụng các thuật toán AI tiên tiến như Tối ưu hóa Bayes (Bayesian Optimization) và Học tăng cường (PPO, SAC) để tìm kiếm phương án đầu tư tối ưu trong không gian tham số rộng lớn. Tầng dưới thực hiện bài toán Điều độ kinh tế (Economic Dispatch) dựa trên Quy hoạch tuyến tính (LP) để đảm bảo tính khả thi vật lý và tính toán chi phí vận hành chi tiết. Hệ thống được thực hiện trên bộ dữ liệu thực tế WECC 180-bus kết hợp với các thông số công nghệ từ NREL ATB 2024.

Kết quả thực nghiệm cho thấy mô hình không chỉ hội tụ nhanh chóng mà còn cung cấp các phương án quy hoạch có tính thực tiễn cao, cân bằng giữa hiệu quả kinh tế và độ tin cậy vận hành. Pipeline phát triển có cấu trúc module linh hoạt, cho phép mở rộng và ứng dụng vào các kịch bản thực tế phức tạp khác nhau.

Abstract

The Generation Expansion Planning (GEP) problem plays a crucial role in ensuring energy security and optimizing power system investment costs. Traditional methods based on Mixed-Integer Linear Programming (MILP) often face computational challenges when scaling up, while pure Reinforcement Learning (RL) models struggle to guarantee strict physical constraints of the power system.

This thesis proposes a Bi-level Hybrid Optimization architecture that combines the advantages of both approaches. The upper level utilizes advanced AI algorithms such as Bayesian Optimization and Reinforcement Learning (PPO, SAC) to search for optimal investment strategies within a large parameter space. The lower level performs the Economic Dispatch problem based on Linear Programming (LP) to ensure physical feasibility and calculate detailed operational costs. The system is implemented on the realistic WECC 180-bus dataset combined with technical parameters from the NREL ATB 2024.

Experimental results demonstrate that the model not only converges rapidly but also provides practical planning alternatives, balancing economic efficiency and operational reliability. The developed pipeline features a flexible modular structure, allowing for expansion and application to various complex real-world scenarios.

Chương 1

Giới thiệu

1.1 Bối cảnh và tầm quan trọng của đề tài

Hệ thống điện đóng vai trò then chốt trong nền kinh tế hiện đại, cung cấp năng lượng cho các hoạt động sản xuất, kinh doanh và sinh hoạt, đồng thời đòi hỏi quá trình vận hành và quy hoạch phải được thực hiện một cách tin cậy và hiệu quả [12, 25]. Cùng với sự gia tăng nhu cầu phụ tải, xu hướng tích hợp năng lượng tái tạo và các công nghệ phát điện sạch ở quy mô lớn đang làm thay đổi đáng kể cấu trúc và yêu cầu vận hành của hệ thống điện hiện đại [13, 14].

Bài toán Quy hoạch mở rộng nguồn điện (Generation Expansion Planning - GEP) là một trong những bài toán trung tâm của quy hoạch hệ thống điện. GEP nhằm xác định phương án đầu tư xây dựng các nguồn phát điện mới một cách tối ưu, cân bằng giữa chi phí đầu tư, chi phí vận hành và độ tin cậy cung cấp điện [12, 18]. Trong bối cảnh biến đổi khí hậu và chuyển dịch năng lượng, GEP không chỉ cần đảm bảo an ninh năng lượng mà còn phải hỗ trợ quá trình tích hợp năng lượng tái tạo và đáp ứng các mục tiêu phát triển bền vững [14].

Các phương pháp truyền thống để giải quyết GEP chủ yếu dựa trên Quy hoạch tuyến tính nguyên hỗn hợp (Mixed-Integer Linear Programming - MILP) và các biến thể tối ưu hóa toán học chính xác [12, 18]. Tuy nhiên, khi quy mô hệ thống tăng lên và mức độ bất định do năng lượng tái tạo ngày càng lớn, các phương pháp này thường gặp phải những hạn chế sau [14]:

- Khó khăn trong việc xử lý các ràng buộc phi tuyến tính phức tạp
- Thời gian tính toán tăng theo cấp số nhân khi quy mô hệ thống lớn
- Khó thích ứng với sự biến động của các thông số đầu vào như giá nhiên liệu, công nghệ mới
- Thường bỏ qua các yếu tố không chắc chắn trong tương lai

Mặt khác, các phương pháp trí tuệ nhân tạo (AI), đặc biệt là Học tăng cường (Reinforcement Learning - RL), đã cho thấy hiệu quả trong các bài toán ra quyết định tuần tự và tối ưu hóa trong không gian hành động phức tạp [7, 21, 24]. Tuy nhiên, việc áp dụng RL thuần túy vào GEP cũng gặp phải những thách thức:

- Khó đảm bảo các ràng buộc vật lý khắt khe của hệ thống điện
- Yêu cầu lượng dữ liệu huấn luyện lớn
- Khó hội tụ trong không gian tìm kiếm rộng lớn

1.2 Mục tiêu nghiên cứu

Đề tài này nhằm phát triển một mô hình tối ưu hóa lai hai tầng (Bi-level Hybrid Optimization) kết hợp ưu điểm của cả MILP và RL để giải quyết bài toán GEP một cách hiệu quả. Cụ thể, các mục tiêu chính bao gồm:

1. Phát triển kiến trúc tối ưu hóa lai hai tầng tích hợp Bayesian Optimization và Reinforcement Learning ở tầng trên với Linear Programming ở tầng dưới [22, 24]
2. Đánh giá hiệu suất của mô hình trên bộ dữ liệu thực tế WECC 180-bus [26]
3. So sánh với các phương pháp truyền thống và hiện đại khác
4. Phát triển pipeline tính toán có cấu trúc module linh hoạt cho các ứng dụng thực tế

1.3 Phạm vi nghiên cứu

Đề tài tập trung vào các nội dung chính sau:

- Nghiên cứu lý thuyết về bài toán GEP và các phương pháp giải quyết [12, 18]
- Phát triển thuật toán tối ưu hóa lai hai tầng
- Thực nghiệm trên hệ thống WECC 180-bus với các kịch bản khác nhau [26]
- Phân tích độ nhạy và độ tin cậy của các phương án quy hoạch

Chương 2

Cơ sở lý thuyết

Chương này trình bày các nền tảng lý thuyết được sử dụng trong đề tài, bao gồm: bài toán Quy hoạch mở rộng nguồn điện (GEP), tối ưu hóa hai tầng (Bi-level Optimization), quy hoạch tuyến tính (LP), tối ưu hóa Bayes (Bayesian Optimization), và học tăng cường (Reinforcement Learning). Mỗi phần lý thuyết đều được phân tích trong mối liên hệ trực tiếp với bài toán đang giải quyết.

2.1 Bài toán Quy hoạch mở rộng nguồn điện (GEP)

2.1.1 Định nghĩa bài toán

Bài toán Quy hoạch mở rộng nguồn điện (Generation Expansion Planning – GEP) là bài toán xác định thời điểm, vị trí, loại công nghệ và quy mô công suất của các nhà máy phát điện mới cần xây dựng trong một khoảng thời gian quy hoạch nhất định, sao cho tổng chi phí hệ thống (bao gồm chi phí đầu tư và chi phí vận hành) được tối thiểu hóa, đồng thời thỏa mãn các ràng buộc về kỹ thuật, kinh tế và môi trường [12].

Về mặt toán học, bài toán GEP tổng quát có thể được phát biểu như sau:

$$\min_{\mathbf{x}} C_{\text{inv}}(\mathbf{x}) + C_{\text{op}}(\mathbf{x}) \quad (2.1)$$

thỏa mãn các ràng buộc:

- Cân bằng cung – cầu công suất tại mọi thời điểm

- Giới hạn công suất phát của từng nhà máy
- Giới hạn truyền tải giữa các vùng
- Ràng buộc về độ tin cậy cung cấp điện
- Ràng buộc về phát thải (nếu có)

2.1.2 Phân loại các phương pháp giải GEP

Theo tổng quan của Sadeghi và cộng sự [18], các phương pháp giải GEP được chia thành ba nhóm chính:

1. **Phương pháp toán học chính xác:** Bao gồm Quy hoạch tuyến tính (LP), Quy hoạch nguyên hỗn hợp (MILP), và Quy hoạch động (DP). Các phương pháp này đảm bảo tìm được nghiệm tối ưu toàn cục nhưng gặp khó khăn khi quy mô bài toán tăng lên (hiện tượng “lời nguyền chiều” – curse of dimensionality) [14].
2. **Phương pháp metaheuristic:** Bao gồm Thuật toán di truyền (GA), Tối ưu bầy đàn (PSO), Mô phỏng luyện kim (SA). Các phương pháp này linh hoạt hơn nhưng không đảm bảo hội tụ về nghiệm tối ưu toàn cục.
3. **Phương pháp dựa trên AI:** Bao gồm Mạng thần kinh nhân tạo, Học tăng cường, và các phương pháp lai. Đây là hướng nghiên cứu mới và được quan tâm ngày càng nhiều nhờ khả năng xử lý các bài toán quy mô lớn với tính bất định cao.

2.2 Tối ưu hóa hai tầng (Bi-level Optimization)

2.2.1 Khái niệm và phát biểu toán học

Tối ưu hóa hai tầng (Bi-level Optimization) là một lớp bài toán tối ưu hóa toán học trong đó một bài toán tối ưu (tầng trên) chứa một bài toán tối ưu khác (tầng dưới) như một ràng buộc [4]. Dạng tổng quát của bài toán bi-level được phát biểu như sau:

$$\min_{\mathbf{x}, \mathbf{y}} F(\mathbf{x}, \mathbf{y}) \quad (\text{Hàm mục tiêu tầng trên}) \quad (2.2)$$

$$\begin{aligned} \text{s.t. } G(\mathbf{x}, \mathbf{y}) &\leq 0 && (\text{Ràng buộc tầng trên}) \\ \mathbf{y} &\in \arg \min_{\mathbf{y}'} \{ f(\mathbf{x}, \mathbf{y}') : g(\mathbf{x}, \mathbf{y}') \leq 0 \} && (\text{Bài toán tầng dưới}) \end{aligned} \quad (2.3)$$

trong đó $\mathbf{x}$ là biến quyết định của tầng trên, $\mathbf{y}$ là biến quyết định của tầng dưới phụ thuộc vào lựa chọn $\mathbf{x}$ của tầng trên.

2.2.2 Đặc điểm của bài toán bi-level

Bài toán bi-level có một số đặc điểm quan trọng [23]:

- **Cấu trúc phân cấp:** Hai bài toán tối ưu có mối quan hệ chủ – phụ (leader – follower). Tầng trên đưa ra quyết định trước, tầng dưới phản hồi tối ưu dựa trên quyết định của tầng trên.
- **Tính NP-hard:** Ngay cả khi cả hai tầng đều là bài toán tuyến tính, bài toán bi-level tổng quát vẫn thuộc lớp NP-hard [9].
- **Phản hồi ngầm:** Nghiệm tối ưu $\mathbf{y}^*(\mathbf{x})$ của tầng dưới là một hàm ngầm (implicit function) của $\mathbf{x}$, khiến hàm mục tiêu tầng trên thường không khả vi (non-differentiable) hoặc phi lồi (non-convex).

2.3 Quy hoạch tuyến tính (Linear Programming)

2.3.1 Lý thuyết cơ bản

Quy hoạch tuyến tính (Linear Programming – LP) là phương pháp tối ưu hóa một hàm mục tiêu tuyến tính trên một miền chấp nhận được xác định bởi các ràng buộc tuyến tính [2]. Dạng chuẩn (standard form) của bài toán LP:

$$\begin{aligned}
\min_{\mathbf{y}} \quad & \mathbf{c}^\top \mathbf{y} \\
\text{s.t.} \quad & A\mathbf{y} = \mathbf{b} \\
& \mathbf{y} \geq \mathbf{0}
\end{aligned} \tag{2.4}$$

trong đó $\mathbf{c} \in \mathbb{R}^n$ là vectơ chi phí, $A \in \mathbb{R}^{m \times n}$ là ma trận ràng buộc, $\mathbf{b} \in \mathbb{R}^m$ là vectơ vế phải.

2.3.2 Thuật toán giải LP

Hai thuật toán chính để giải LP là:

1. **Phương pháp Đơn hình (Simplex Method):** Do Dantzig đề xuất năm 1947 [5], phương pháp này duyệt qua các đỉnh của đa diện chấp nhận được. Mặc dù có độ phức tạp trường hợp xấu nhất là hàm mũ, trên thực tế Simplex thường hoạt động rất hiệu quả.
2. **Phương pháp Điểm trong (Interior Point Method):** Do Karmarkar đề xuất năm 1984 [11], phương pháp này di chuyển qua phần bên trong của miền chấp nhận được. Có độ phức tạp đa thức $O(n^{3.5}L)$ với L là kích thước đầu vào.

2.3.3 Bài toán Điều độ kinh tế (Economic Dispatch)

Bài toán Điều độ kinh tế (Economic Dispatch – ED) là bài toán phân bổ công suất phát cho các nhà máy phát điện sao cho tổng chi phí vận hành là nhỏ nhất, đồng thời thỏa mãn cân bằng cung – cầu và các ràng buộc kỹ thuật [25]. Khi hàm chi phí được xấp xỉ tuyến tính, ED trở thành một bài toán LP.

Trong đề tài, bài toán ED theo từng giờ t được phát biểu:

$$\min_{P_i^t, F_{zz'}^t, \Delta L_z^t} \sum_{i \in \mathbf{G}} c_i P_i^t + \beta \sum_{z \in \mathbf{Z}} \Delta L_z^t \tag{2.5}$$

thỏa mãn:

(i) Cân bằng công suất từng vùng:

$$\sum_{i \in \mathbf{G}_z} P_i^t + \sum_{z' \neq z} F_{z'z}^t - \sum_{z' \neq z} F_{zz'}^t + \Delta L_z^t = D_z^t, \quad \forall z \in \mathbf{Z} \quad (2.6)$$

(ii) Giới hạn công suất phát:

$$0 \leq P_i^t \leq P_i^{\max} \cdot \text{CF}_i(t), \quad \forall i \in \mathbf{G} \quad (2.7)$$

(iii) Giới hạn truyền tải liên vùng:

$$-F_{zz'}^{\max} \leq F_{zz'}^t \leq F_{zz'}^{\max}, \quad \forall (z, z') \in \mathbf{L} \quad (2.8)$$

(iv) Biến cắt tải không âm:

$$\Delta L_z^t \geq 0, \quad \forall z \in \mathbf{Z} \quad (2.9)$$

trong đó:

- P_i^t : Công suất phát của tổ máy i tại giờ t (MW)
- c_i : Chi phí biên vận hành của tổ máy i (\$/MWh)
- $F_{zz'}^t$: Công suất truyền tải từ vùng z sang vùng z' tại giờ t (MW)
- ΔL_z^t : Lượng cắt tải tại vùng z , giờ t (MW)
- D_z^t : Phụ tải tại vùng z , giờ t (MW)
- $\text{CF}_i(t) \in [0, 1]$: Hệ số công suất (Capacity Factor) theo giờ
- $\beta = \text{VOLL}$: Value of Lost Load – giá trị kinh tế của mỗi MWh bị cắt tải

2.4 Tối ưu hóa Bayes (Bayesian Optimization)

2.4.1 Khái niệm và động lực

Tối ưu hóa Bayes (Bayesian Optimization – BO) là phương pháp tối ưu hóa toàn cục dành cho các hàm mục tiêu dạng *hộp đen* (black-box function) có chi phí đánh giá đắt đỏ [22]. Khác với các phương pháp

dựa trên gradient, BO không yêu cầu biết dạng giải tích hay đạo hàm của hàm mục tiêu, mà thay vào đó xây dựng một mô hình xác suất xấp xỉ (surrogate model) dựa trên các quan sát đã thu thập.

Bài toán BO được phát biểu:

$$\mathbf{x}^* = \arg \min_{\mathbf{x} \in \mathbf{X}} f(\mathbf{x}) \quad (2.10)$$

trong đó f là hàm mục tiêu đắt đỏ (expensive-to-evaluate), $\mathbf{X}$ là miền tìm kiếm, và ta không có quyền truy cập vào gradient ∇f .

2.4.2 Các thành phần cốt lõi

BO gồm hai thành phần chính [6]:

Mô hình thay thế (Surrogate Model) Mô hình thay thế là một mô hình xác suất xấp xỉ hàm mục tiêu $f(\mathbf{x})$ dựa trên tập dữ liệu đã quan sát $\mathbf{D}_n = \{(\mathbf{x}_i, y_i)\}_{i=1}^n$. Hai lựa chọn phổ biến nhất:

- **Gaussian Process (GP):** Mô hình GP định nghĩa một phân phối trên không gian hàm, nơi mỗi tập con hữu hạn tuân theo phân phối chuẩn đa biến [16]:

$$f(\mathbf{x}) \sim \text{GP}(m(\mathbf{x}), k(\mathbf{x}, \mathbf{x}')) \quad (2.11)$$

với $m(\mathbf{x})$ là hàm trung bình và $k(\mathbf{x}, \mathbf{x}')$ là hàm hiệp phương sai (kernel).

- **Tree-structured Parzen Estimator (TPE):** Do Bergstra và cộng sự đề xuất [1], TPE mô hình hóa hai mật độ xác suất có điều kiện:

$$p(\mathbf{x} | y) = \begin{cases} l(\mathbf{x}) & \text{nếu } y < y^* \\ g(\mathbf{x}) & \text{nếu } y \geq y^* \end{cases} \quad (2.12)$$

trong đó y^* là ngưỡng phân chia (thường là quantile), $l(\mathbf{x})$ là mật độ các điểm “tốt”, $g(\mathbf{x})$ là mật độ các điểm “kém”. Tỷ số $l(\mathbf{x})/g(\mathbf{x})$ cao tương ứng với vùng có triển vọng tốt.

Hàm thu thập (Acquisition Function) Hàm thu thập $\alpha(\mathbf{x})$ quyết định điểm nào sẽ được đánh giá tiếp theo, bằng cách cân bằng giữa *khai thác* (exploitation) – thử nghiệm tại vùng đã biết tốt, và *khám phá* (exploration) – thử nghiệm tại vùng chưa biết nhiều.

Expected Improvement (EI) là hàm thu thập phổ biến nhất [10]:

$$\text{EI}(\mathbf{x}) = \mathbb{E}[\max(f_{\min} - f(\mathbf{x}), 0)] \quad (2.13)$$

trong đó $f_{\min}$ là giá trị tốt nhất đã quan sát được. Điểm tiếp theo được chọn bằng:

$$\mathbf{x}_{n+1} = \arg \max_{\mathbf{x} \in \mathbf{X}} \text{EI}(\mathbf{x}) \quad (2.14)$$

2.4.3 Quy trình tối ưu hóa Bayes

Thuật toán BO hoạt động theo các bước vòng lặp tuần tự cơ bản sau:

1. Khởi tạo: Đánh giá hàm f tại n_0 điểm ngẫu nhiên trong $\mathbf{X}$
2. Lặp cho đến khi hết ngân sách (budget):
 - (a) Cập nhật mô hình thay thế dựa trên $\mathbf{D}_n$
 - (b) Tối ưu hàm thu thập $\alpha(\mathbf{x})$ để tìm $\mathbf{x}_{n+1}$
 - (c) Đánh giá $y_{n+1} = f(\mathbf{x}_{n+1})$
 - (d) Cập nhật $\mathbf{D}_{n+1} = \mathbf{D}_n \cup \{(\mathbf{x}_{n+1}, y_{n+1})\}$
3. Trả về $\mathbf{x}^* = \arg \min_{(\mathbf{x}_i, y_i) \in \mathbf{D}} y_i$

2.5 Quá trình quyết định Markov (MDP)

2.5.1 Định nghĩa

Quá trình quyết định Markov (Markov Decision Process – MDP) là khung toán học mô tả bài toán ra quyết định tuần tự trong môi trường có tính ngẫu nhiên [15]. Một MDP được xác định bởi bộ năm $(\mathbf{S}, \mathbf{A}, P, R, \gamma)$:

- $\mathbf{S}$: Không gian trạng thái (state space)
- $\mathbf{A}$: Không gian hành động (action space)
- $P(s' | s, a)$: Hàm chuyển trạng thái (transition probability)

- $R(s, a)$: Hàm phần thưởng (reward function)
- $\gamma \in [0, 1]$: Hệ số chiết khấu (discount factor)

Tính chất Markov cho rằng trạng thái tương lai chỉ phụ thuộc vào trạng thái hiện tại, không phụ thuộc vào lịch sử:

$$P(s_{t+1} \mid s_t, a_t, s_{t-1}, a_{t-1}, \dots) = P(s_{t+1} \mid s_t, a_t) \quad (2.15)$$

2.5.2 Chính sách và hàm giá trị

Chính sách (Policy) $\pi : \mathbf{S} \rightarrow \mathbf{P}(\mathbf{A})$ ánh xạ mỗi trạng thái sang một phân phối xác suất trên không gian hành động. Mục tiêu là tìm chính sách π^* cực đại hóa tổng phần thưởng kỳ vọng:

$$\pi^* = \arg \max_{\pi} \mathbb{E}_{\pi} \left[\sum_{t=0}^{\infty} \gamma^t R(s_t, a_t) \right] \quad (2.16)$$

Hàm giá trị trạng thái (State-value function):

$$V^{\pi}(s) = \mathbb{E}_{\pi} \left[\sum_{t=0}^{\infty} \gamma^t R(s_t, a_t) \mid s_0 = s \right] \quad (2.17)$$

Hàm giá trị hành động (Action-value function):

$$Q^{\pi}(s, a) = \mathbb{E}_{\pi} \left[\sum_{t=0}^{\infty} \gamma^t R(s_t, a_t) \mid s_0 = s, a_0 = a \right] \quad (2.18)$$

Phương trình Bellman: Mỗi quan hệ đệ quy giữa giá trị của các trạng thái kế tiếp:

$$V^{\pi}(s) = \sum_a \pi(a|s) \left[R(s, a) + \gamma \sum_{s'} P(s'|s, a) V^{\pi}(s') \right] \quad (2.19)$$

2.6 Học tăng cường (Reinforcement Learning)

2.6.1 Tổng quan

Học tăng cường (Reinforcement Learning – RL) là nhánh của machine learning trong đó một tác tử (agent) học cách hành động thông qua tương tác trực tiếp với môi trường, nhận tín hiệu phần thưởng để cải thiện chính sách theo thời gian [24]. Khác với học có giám sát (supervised learning), RL không yêu cầu dữ liệu huấn luyện với nhãn cho trước, mà tác tử tự khám phá và khai thác.

2.6.2 Phương pháp Policy Gradient

Trong các bài toán với không gian hành động liên tục (như bài toán GEP), các phương pháp Policy Gradient được ưu tiên sử dụng [19]. Ý tưởng cốt lõi là tham số hóa chính sách $\pi_\theta(a|s)$ bằng mạng thần kinh với tham số θ , và cập nhật θ theo hướng gradient của hàm mục tiêu:

$$\nabla_\theta J(\theta) = \mathbb{E}_{\pi_\theta} [\nabla_\theta \log \pi_\theta(a_t|s_t) \cdot A^{\pi_\theta}(s_t, a_t)] \quad (2.20)$$

trong đó $A^\pi(s, a) = Q^\pi(s, a) - V^\pi(s)$ là hàm lợi thế (advantage function), đo lường mức độ “tốt hơn trung bình” của hành động a tại trạng thái s .

2.6.3 PPO – Proximal Policy Optimization

PPO do Schulman và cộng sự đề xuất năm 2017 [21] là một thuật toán policy gradient với cơ chế giới hạn bước cập nhật chính sách, đảm bảo quá trình huấn luyện ổn định.

Hàm mục tiêu có kẹp (Clipped Objective) PPO sử dụng hàm mục tiêu có kẹp (clipped surrogate objective):

$$L^{\text{CLIP}}(\theta) = \hat{\mathbb{E}}_t [\min(r_t(\theta)\hat{A}_t, \text{clip}(r_t(\theta), 1 - \epsilon, 1 + \epsilon)\hat{A}_t)] \quad (2.21)$$

trong đó:

- $r_t(\theta) = \frac{\pi_\theta(a_t|s_t)}{\pi_{\theta_{\text{old}}}(a_t|s_t)}$ là tỷ số xác suất (probability ratio)
- $\hat{A}_t$ là ước lượng hàm lợi thế (thường dùng GAE – Generalized Advantage Estimation [20])
- ε là siêu tham số kẹp (thường $\varepsilon = 0.2$)

Phép kẹp ngăn chặn các bước cập nhật quá lớn: khi $r_t(\theta)$ ra ngoài khoảng $[1 - \varepsilon, 1 + \varepsilon]$, gradient bị triệt tiêu, bảo vệ quá trình huấn luyện khỏi sự bất ổn.

Ưu điểm của PPO

- Đơn giản trong triển khai so với TRPO (Trust Region Policy Optimization)
- Ổn định và ít nhạy cảm với siêu tham số
- Hiệu quả trên nhiều loại bài toán khác nhau
- Thuộc loại *on-policy*: sử dụng dữ liệu mới nhất từ chính sách hiện tại

2.6.4 SAC – Soft Actor-Critic

SAC do Haarnoja và cộng sự đề xuất năm 2018 [7] là thuật toán RL off-policy dựa trên nguyên lý cực đại hóa entropy (maximum entropy RL).

Nguyên lý cực đại hóa Entropy SAC tối ưu hàm mục tiêu mở rộng bao gồm cả entropy của chính sách:

$$\pi^* = \arg \max_{\pi} \mathbb{E}_{\pi} \left[\sum_{t=0}^{\infty} \gamma^t (R(s_t, a_t) + \alpha H(\pi(\cdot|s_t))) \right] \quad (2.22)$$

trong đó $H(\pi(\cdot|s)) = -\mathbb{E}_{a \sim \pi}[\log \pi(a|s)]$ là entropy Shannon của chính sách, và $\alpha > 0$ là hệ số nhiệt độ (temperature coefficient) điều chỉnh mức độ khám phá.

Kiến trúc Actor-Critic SAC sử dụng kiến trúc Actor-Critic với ba thành phần mạng neuron:

- **Actor π_ϕ** : Xuất ra phân phối hành động (thường là Gaussian) dựa trên trạng thái. Hàm cập nhật:

$$J_\pi(\phi) = \mathbb{E}_{s_t \sim \mathbf{D}} \left[\mathbb{E}_{a_t \sim \pi_\phi} [\alpha \log \pi_\phi(a_t | s_t) - Q_\psi(s_t, a_t)] \right] \quad (2.23)$$

- **Critic Q_ψ (hai mạng)**: Ước lượng hàm Q-value mềm (soft Q-function). Sử dụng hai mạng critic (Q_{ψ_1}, Q_{ψ_2}) và lấy min để giảm overestimation bias:

$$J_Q(\psi_i) = \mathbb{E}_{(s_t, a_t) \sim \mathbf{D}} \left[\frac{1}{2} (Q_{\psi_i}(s_t, a_t) - \hat{Q}(s_t, a_t))^2 \right] \quad (2.24)$$

với target value:

$$\hat{Q}(s_t, a_t) = R(s_t, a_t) + \gamma \mathbb{E}_{s_{t+1}} \left[\min_{j=1,2} Q_{\tilde{\psi}_j}(s_{t+1}, \tilde{a}_{t+1}) - \alpha \log \pi_\phi(\tilde{a}_{t+1} | s_{t+1}) \right] \quad (2.25)$$

Ưu điểm của SAC so với PPO

- **Off-policy**: Có thể tái sử dụng dữ liệu từ replay buffer, tăng hiệu quả mẫu (sample efficiency)
- **Khám phá tự động**: Entropy regularization giúp chính sách duy trì tính đa dạng, tránh hội tụ sớm về cực trị địa phương
- **Tự điều chỉnh α** : Phiên bản cải tiến tự động điều chỉnh hệ số nhiệt độ α dựa trên entropy mục tiêu [8]

2.7 Chi phí đầu tư niên kim hóa (Annualized CAPEX)

2.7.1 Nhân tử thu hồi vốn (Capital Recovery Factor)

Để so sánh công bằng giữa chi phí đầu tư một lần và chi phí vận hành hàng năm, chi phí đầu tư được quy đổi thành dòng tiền hàng năm đều nhau trong suốt vòng đời kinh tế của công nghệ. Công cụ toán học sử dụng là Nhân tử thu hồi vốn (Capital Recovery Factor – CRF) [3]:

$$\text{CRF}(r, n) = \frac{r(1+r)^n}{(1+r)^n - 1} \quad (2.26)$$

trong đó:

- r : Lãi suất chiết khấu (WACC – Weighted Average Cost of Capital), trong đề tài $r = 7\%$
- n : Tuổi thọ kinh tế của công nghệ (năm)

Chi phí đầu tư niên kim hóa:

$$C_{\text{inv}}(\mathbf{x}) = \sum_{z \in \mathbf{Z}} \sum_{k \in \mathbf{K}} x_{z,k} \cdot \text{CAPEX}_k \cdot \text{CRF}(r, n_k) \quad (2.27)$$

2.8 Phân tích kịch bản ngẫu nhiên (Stochastic Scenario Analysis)

2.8.1 Mô phỏng Monte Carlo

Mô phỏng Monte Carlo là phương pháp sử dụng lấy mẫu ngẫu nhiên lặp lại để ước lượng các đại lượng thống kê của một hệ thống phức tạp [17]. Thay vì giả định rằng các tham số đầu vào luôn cố định, phương pháp này mô hình hóa chúng như những biến ngẫu nhiên và đánh giá hiệu năng hệ thống trên nhiều lần lấy mẫu khác nhau. Trong bối cảnh Quy hoạch mở rộng nguồn điện (GEP), cách tiếp cận này đặc biệt phù hợp vì bài toán quy hoạch luôn chịu tác động của các yếu tố bất định khó dự báo chính xác trong dài hạn [12, 14].

Các nguồn bất định quan trọng trong GEP có thể kể đến như sau:

- **Phụ tải điện:** Nhu cầu tiêu thụ thay đổi theo mùa, theo giờ, và chịu ảnh hưởng mạnh của thời tiết, tăng trưởng kinh tế hoặc hành vi người dùng.
- **Nguồn tái tạo:** Điện gió và điện mặt trời phụ thuộc trực tiếp vào điều kiện khí tượng, nên công suất khả dụng có thể dao động lớn ngay cả khi công suất lắp đặt không đổi.
- **Chi phí và thông số công nghệ:** Giá nhiên liệu, hiệu suất vận

hành, hệ số công suất, tuổi thọ kinh tế và chi phí bảo trì đều có thể biến thiên theo thời gian.

- **Điều kiện vận hành hệ thống:** Nghịch cảnh truyền tải, sự cố tổ máy hoặc các tình huống thời tiết cực đoan có thể làm suy giảm đáng kể khả năng cung ứng điện.

Nếu chỉ tối ưu trên một quỹ đạo dữ liệu duy nhất (deterministic trajectory), phương án đầu tư nhận được có thể đạt chi phí thấp trên bộ dữ liệu đó nhưng lại rất mong manh khi hệ thống phải đối mặt với các trạng thái bất lợi ngoài mẫu. Vì vậy, Monte Carlo được sử dụng để thay thế cách nhìn một-kịch-bản bằng cách đánh giá một phương án đầu tư trên cả một phân phối các trạng thái tương lai có thể xảy ra.

Gọi ξ là vectơ ngẫu nhiên đại diện cho toàn bộ yếu tố bất định của hệ thống, chẳng hạn hồ sơ phụ tải, khả dụng của nguồn tái tạo hoặc các cú sốc ngắn hạn trong vận hành. Khi đó, hàm phạt tổng quát của bài toán không còn là $J(\mathbf{x})$ theo nghĩa xác định, mà trở thành một hàm phụ thuộc vào trạng thái ngẫu nhiên:

$$J(\mathbf{x}, \xi) \quad (2.28)$$

Mục tiêu của quy hoạch lúc này không còn là tìm nghiệm tốt nhất cho một trạng thái duy nhất, mà là tìm phương án đầu tư có hiệu năng tốt theo một tiêu chí thống kê trên toàn bộ phân phối của ξ .

Giá trị kỳ vọng của hàm mục tiêu trên N kịch bản ngẫu nhiên:

$$\bar{J}(\mathbf{x}) = \frac{1}{N} \sum_{i=1}^N J_i(\mathbf{x}) \quad (2.29)$$

trong đó $J_i(\mathbf{x})$ là điểm phạt ứng với kịch bản i của profile phụ tải và năng lượng tái tạo.

Về mặt xác suất, biểu thức trên chính là xấp xỉ mẫu của kỳ vọng toán học:

$$\mathbb{E}_{\xi}[J(\mathbf{x}, \xi)] \approx \frac{1}{N} \sum_{i=1}^N J(\mathbf{x}, \xi_i) \quad (2.30)$$

Trong đó, mỗi ξ_i là một mẫu độc lập hoặc bán độc lập được sinh ra từ cơ chế mô phỏng kịch bản. Khi N tăng lên, trung bình mẫu sẽ hội tụ dần về kỳ vọng thực của hàm mục tiêu theo định luật số lớn [17]. Điều này cho phép biến một bài toán tối ưu dưới bất định thành một bài toán tối ưu trên giá trị trung bình của nhiều lần mô phỏng.

Từ góc nhìn tối ưu hóa, đây là dạng *sample-average approximation*: tầng trên chọn một phương án đầu tư $\mathbf{x}$, tầng dưới đánh giá phương án đó trên nhiều kịch bản ngẫu nhiên, rồi lấy trung bình chi phí để phản hồi lại cho bộ tối ưu. Với cách tổ chức này, Monte Carlo đóng vai trò cầu nối giữa thế giới thực nhiều bất định và mô hình tối ưu hóa cần một hàm đánh giá đủ ổn định để có thể so sánh giữa các phương án đầu tư khác nhau.

Ý nghĩa của phân tích kịch bản ngẫu nhiên không chỉ nằm ở việc làm tăng độ chân thực của bài toán, mà còn ở khả năng bộc lộ rõ các đánh đổi kinh tế – kỹ thuật. Một phương án đầu tư rất rẻ có thể cho giá trị tốt trong kịch bản cơ sở, nhưng lại gây cắt tải lớn trong các trạng thái hiếm song nghiêm trọng. Ngược lại, một phương án có dự phòng cao hơn có thể làm tăng CAPEX ban đầu nhưng giúp ổn định chi phí vận hành, giảm thiểu rủi ro thiếu điện, và tăng độ bền vững của hệ thống trước các tổ hợp bất lợi của phụ tải và năng lượng tái tạo.

Vì vậy, trong GEP hiện đại, Monte Carlo không đơn thuần là công cụ mô phỏng mà còn là cơ chế định lượng *khả năng chống chịu* của một kế hoạch đầu tư. Nói cách khác, thay vì hỏi “phương án nào rẻ nhất trong điều kiện lý tưởng?”, phân tích kịch bản ngẫu nhiên đặt ra câu hỏi thực tế hơn: “phương án nào vẫn vận hành chấp nhận được khi tương lai không diễn ra đúng như kỳ vọng?”.

2.8.2 Liên hệ với đề tài

Trong đề tài này, phân tích kịch bản ngẫu nhiên được sử dụng như nền tảng lý thuyết cho kịch bản *robust* ở các chương sau. Cụ thể, với

mỗi véctơ đầu tư $\mathbf{x}$ do tầng trên đề xuất, hệ thống không đánh giá ngay trên một bộ dữ liệu phụ tải – tái tạo cố định, mà sinh ra nhiều kịch bản Monte Carlo khác nhau để tính:

$$\bar{J}(\mathbf{x}) = \alpha C_{\text{inv}}(\mathbf{x}) + \frac{1}{N} \sum_{i=1}^N [\alpha C_{\text{op}}^*(\mathbf{x}, \xi_i) + \beta S_{\text{total}}(\mathbf{x}, \xi_i)] \quad (2.31)$$

Trong đó, phần bất định chủ yếu đến từ nhiều phụ tải và sự suy giảm công suất khả dụng của điện gió, điện mặt trời. Nhờ đó, tầng trên không còn tối ưu cho một quỹ đạo “đẹp” duy nhất mà buộc phải tìm nghiệm có hiệu quả trung bình tốt trên nhiều trạng thái vận hành khác nhau.

Điều này giải thích trực tiếp cho các kết quả thực nghiệm ở chương kết quả: nghiệm robust của đề tài có thể không phải là nghiệm rẻ nhất trên tập ngày đại diện ban đầu, nhưng thường có xu hướng dịch chuyển về những công nghệ điều độ được hơn hoặc có khả năng bù đắp biến thiên tốt hơn, chẳng hạn gas_ccs và hệ thống lưu trữ. Nói cách khác, Monte Carlo giúp tiêu chí tối ưu phản ánh gần hơn nhu cầu thực của quy hoạch điện: không chỉ tối ưu về mặt chi phí trung bình, mà còn phải đủ bền vững trước các nhiễu động trong tương lai.

2.9 Tổng kết chương

Chương này đã trình bày các nền tảng lý thuyết cốt lõi được sử dụng trong đề tài. Bảng 2.9.1 tóm tắt vai trò của từng lý thuyết trong hệ thống bi-level.

Các chương tiếp theo sẽ trình bày chi tiết cách các lý thuyết này được kết hợp và hiện thực hóa trong kiến trúc tối ưu hóa lai hai tầng đề xuất.

Lý thuyết	Vị trí	Vai trò trong đề tài
GEP	Toàn bộ hệ thống	Bài toán chính cần giải quyết
Bi-level Optimization	Kiến trúc tổng thể	Phân tách quyết định đầu tư và vận hành
Linear Programming	Tầng dưới	Giải bài toán điều độ kinh tế
Bayesian Optimization	Tầng trên	Tìm phương án đầu tư tối ưu (black-box)
MDP	Tầng trên	Khung bài toán cho RL
PPO	Tầng trên	Thuật toán RL on-policy ổn định
SAC	Tầng trên	Thuật toán RL off-policy với entropy
CRF / Niên kim hóa	Hàm mục tiêu	Quy đổi CAPEX thành chi phí hàng năm
Monte Carlo	Đánh giá	Phân tích tính bền vững dưới bất định

Bảng 2.9.1: Tóm tắt vai trò của các lý thuyết trong hệ thống bi-level.

Chương 3

Mô hình hóa bài toán quy hoạch mở rộng nguồn điện

Dựa trên các nền tảng lý thuyết đã được trình bày ở Chương 2, chương này đi sâu vào việc xây dựng và công thức hóa bài toán cốt lõi của đề tài: Bài toán Quy hoạch mở rộng nguồn điện (GEP) giải quyết bằng kiến trúc tối ưu hóa lai hai tầng (Bi-level Hybrid Optimization). Cách tiếp cận này giúp khắc phục giới hạn của các phương pháp truyền thống khi phải đối mặt với không gian tìm kiếm rộng lớn và tính bất định của năng lượng tái tạo, đồng thời đảm bảo các ràng buộc vật lý khắt khe của hệ thống điện.


3.1 Khung mô hình tối ưu hóa lai hai tầng

Bài toán quy hoạch mở rộng nguồn điện vốn yêu cầu xem xét đồng thời quyết định đầu tư dài hạn (xây nhà máy gì, ở đâu, công suất bao nhiêu) và quyết định vận hành ngắn hạn (huy động các nhà máy như thế nào để đáp ứng phụ tải từng giờ). Để giải quyết bài toán này một cách khả thi và hiệu quả, đề tài đề xuất phân tách bài toán thành cấu trúc hai tầng (Bi-level):

- **Tầng trên (Upper Level):** Đóng vai trò là “Nhà hoạch định chiến lược”. Tầng này sử dụng các thuật toán Trí tuệ nhân tạo (Học tăng cường hoặc Tối ưu hóa Bayes) để tìm kiếm và đề xuất các phương án đầu tư công suất (véctơ $\mathbf{x}$).

- **Tầng dưới (Lower Level):** Đóng vai trò là “Điều độ viên hệ thống”. Tầng này nhận phương án đầu tư từ tầng trên, cập nhật cấu trúc lưới điện, và giải bài toán Quy hoạch tuyến tính (LP) để mô phỏng vận hành hệ thống trong suốt một năm (hoặc các ngày đại diện). Tầng dưới sau đó sẽ trả về kết quả là chi phí vận hành và lượng cắt tải (nếu có) cho tầng trên.

Vòng lặp tương tác giữa hai tầng giúp các thuật toán AI ở tầng trên dần dần “học” được đâu là phương án đầu tư mang lại hiệu quả kinh tế cao nhất và đảm bảo an ninh năng lượng tốt nhất mà không cần phải hiểu trực tiếp các phương trình dòng điện phức tạp ở tầng dưới.



Hình 3.1.1: Sơ đồ luồng thông tin trong kiến trúc tối ưu hóa lai hai tầng

3.2 Mô hình toán học tầng dưới cho bài toán điều độ kinh tế

Mục tiêu của bài toán tầng dưới là tối thiểu hóa tổng chi phí vận hành hệ thống và chi phí phạt do cắt tải, với điều kiện hệ thống đã được bổ sung thêm công suất từ quyết định đầu tư của tầng trên.

3.2.1 Tập hợp, tham số và biến quyết định

Tập hợp (Sets):

- **Z:** Tập hợp các vùng (Zones) trong hệ thống, chỉ số z .

- **G**: Tập hợp tất cả các máy phát điện (bao gồm cả hiện hữu và xây mới), chỉ số i . G_z là tập các máy phát thuộc vùng z .
- **L**: Tập hợp các đường dây truyền tải liên kết giữa các vùng, chỉ số cặp (z, z') .
- **T**: Tập hợp các khung giờ vận hành trong năm mô phỏng, chỉ số t .

Tham số (Parameters):

- D_z^t : Nhu cầu phụ tải tại vùng z trong giờ t (MW).
- $P_i^{\max}$: Công suất đặt tối đa của máy phát i (MW). Đối với các máy phát được đầu tư mới, thông số này chính là biến quyết định được nhận từ tầng trên.
- c_i : Chi phí biên vận hành của máy phát i (\$/MWh), bao gồm cả thuế carbon đối với nhiên liệu hóa thạch.
- $CF_i(t) \in [0, 1]$: Hệ số công suất khả dụng theo giờ của tổ máy i . Đối với điện mặt trời và điện gió, giá trị này biến thiên theo dữ liệu khí tượng. Đối với nhiệt điện, $CF_i(t) = 1$. Đối với hệ thống lưu trữ (BESS), $CF_i(t)$ đại diện cho tỷ lệ xả trung bình cho phép.
- $F_{zz'}^{\max}$: Giới hạn công suất truyền tải tối đa trên hành lang liên vùng từ z đến z' (MW).
- β : Giá trị tổn thất điện năng (Value of Lost Load – VOLL), đại diện cho mức phạt kinh tế cho mỗi MWh bị cắt tải (\$/MWh).

Biến quyết định (Decision Variables):

- P_i^t : Công suất phát thực tế của tổ máy i trong giờ t (MW).
- $F_{zz'}^t$: Công suất truyền tải từ vùng z sang vùng z' trong giờ t (MW).
- ΔL_z^t : Lượng công suất phụ tải bị cắt (Load shedding) tại vùng z trong giờ t (MW) nhằm tránh sụp đổ hệ thống khi cung không đủ cầu.

3.2.2 Hàm mục tiêu và hệ ràng buộc

Hàm mục tiêu vận hành của tầng dưới được công thức hóa dưới dạng quy hoạch tuyến tính (LP) cho mỗi giờ t :

$$C_{\text{op}}^t(\mathbf{x}) = \min_{P_i^t, F_{zz'}^t, \Delta L_z^t} \left(\sum_{i \in \mathbf{G}} c_i P_i^t + \beta \sum_{z \in \mathbf{Z}} \Delta L_z^t \right) \quad (3.1)$$

Hệ phương trình này tuân thủ các ràng buộc vật lý cơ bản:

1. Cân bằng công suất từng vùng (Power Balance Constraint):

Tổng công suất phát nội vùng, cộng với điện năng truyền tải đến, trừ đi điện năng truyền tải đi, và cộng với lượng cắt tải phải bằng đúng nhu cầu phụ tải tại mọi thời điểm.

$$\sum_{i \in \mathbf{G}_z} P_i^t + \sum_{z' \neq z} F_{z'z}^t - \sum_{z' \neq z} F_{zz'}^t + \Delta L_z^t = D_z^t, \quad \forall z \in \mathbf{Z} \quad (3.2)$$

2. Giới hạn công suất phát (Generation Limits): Công suất phát không được vượt quá giới hạn đặt và bị phụ thuộc vào hệ số khả dụng thời tiết (đối với năng lượng tái tạo).

$$0 \leq P_i^t \leq P_i^{\max}(\mathbf{x}) \cdot \text{CF}_i(t), \quad \forall i \in \mathbf{G} \quad (3.3)$$

3. Giới hạn truyền tải liên vùng (Transmission Limits):

$$-F_{zz'}^{\max} \leq F_{zz'}^t \leq F_{zz'}^{\max}, \quad \forall (z, z') \in \mathbf{L} \quad (3.4)$$

4. Điều kiện không âm của biến cắt tải:

$$\Delta L_z^t \geq 0, \quad \forall z \in \mathbf{Z} \quad (3.5)$$

Việc giải hệ LP này trong suốt T giờ vận hành sẽ cung cấp tổng chi phí vận hành $C_{\text{op}}^*(\mathbf{x}) = \sum_{t=1}^T C_{\text{op}}^t(\mathbf{x})$ và tổng lượng cắt tải $S_{\text{total}}(\mathbf{x}) = \sum_{t=1}^T \sum_z \Delta L_z^t$. Nhờ sự đơn giản hóa cấu trúc không gian (zonal model) và tính chất lồi của quy hoạch tuyến tính, bộ giải (ví dụ như HiGHS solver) có thể trả về kết quả cực kỳ nhanh chóng với độ chính xác toàn cục, tạo

nền tảng vững chắc cho việc đánh giá lặp lại ở tầng trên.

3.3 Mô hình toán học tầng trên cho bài toán quy hoạch mở rộng nguồn điện

Tầng trên chịu trách nhiệm quyết định đầu tư công suất. Mục tiêu là tối thiểu hóa tổng chi phí của toàn hệ thống (Bao gồm chi phí đầu tư dài hạn và chi phí vận hành ngắn hạn do tầng dưới phản hồi).

3.3.1 Biến quyết định của bài toán đầu tư

Cho tập hợp các công nghệ xây dựng mới $\mathbf{K} = \{\text{Solar}, \text{Wind}, \text{Gas_CCS}, \text{Battery}\}$, biến quyết định của tầng trên là vectơ đầu tư $\mathbf{x}$:

$$\mathbf{x} = [x_{z,k}], \quad \forall z \in \mathbf{Z}, \forall k \in \mathbf{K} \quad (3.6)$$

trong đó $x_{z,k} \geq 0$ là quy mô công suất (MW) của công nghệ k sẽ được xây dựng mới tại vùng z . Không gian tìm kiếm bị giới hạn bởi tiềm năng phát triển tối đa của từng vùng $x_{z,k} \leq X_{z,k}^{\max}$.

3.3.2 Hàm mục tiêu tổng quát của tầng trên

Để có thể cộng trực tiếp chi phí đầu tư ban đầu (CAPEX) với chi phí vận hành hàng năm (OPEX), đề tài áp dụng phương pháp niên kim hóa thông qua nhân tử thu hồi vốn $\text{CRF}(r, n_k)$. Chi phí đầu tư quy đổi hàng năm được tính như sau:

$$C_{\text{inv}}(\mathbf{x}) = \sum_{z \in \mathbf{Z}} \sum_{k \in \mathbf{K}} x_{z,k} \cdot \text{CAPEX}_k \cdot \text{CRF}(r, n_k) \quad (3.7)$$

Dựa trên phản hồi từ tầng dưới, hàm mục tiêu tổng (hay Điểm phạt – Penalty Score) mà tầng trên cần tối thiểu hóa là:

$$J(\mathbf{x}) = \alpha \left[C_{\text{inv}}(\mathbf{x}) + C_{\text{op}}^*(\mathbf{x}) \right] + \beta \cdot S_{\text{total}}(\mathbf{x}) \quad (3.8)$$

trong đó α là hệ số trọng số cho chi phí tài chính (thường đặt là 1.0) và β là hình phạt rất lớn khi để xảy ra tình trạng cắt điện (VOLL).

Do $C_{\text{op}}^*(\mathbf{x})$ và $S_{\text{total}}(\mathbf{x})$ là nghiệm của một bài toán tối ưu khác ở tầng

dưới nên hàm $J(\mathbf{x})$ không có dạng biểu thức giải tích tường minh (implicit function) và cũng không thể lấy đạo hàm ∇J theo $\mathbf{x}$. $J(\mathbf{x})$ chính thức trở thành một **hàm hộp đen (black-box function)**.

3.4 Mô hình hóa tính bất định thông qua phân tích kịch bản Monte Carlo

Lưới điện hiện đại đối mặt với tính bất định sâu sắc từ nhu cầu phụ tải và sự biến thiên của năng lượng tái tạo. Nếu hệ thống chỉ tối ưu trên một bộ dữ liệu tĩnh (deterministic), phương án đầu tư có thể rất rẻ nhưng sẽ sụp đổ khi có các dị thường thời tiết (ví dụ: chuỗi ngày ít gió và râm mát).

Để đảm bảo tính bền vững (Robustness), đề tài áp dụng mô phỏng Monte Carlo. Tầng dưới không chỉ chạy trên một hồ sơ tĩnh mà đối với mỗi quyết định $\mathbf{x}$, hệ thống sinh ra một tập hợp N kịch bản ngẫu nhiên (scenarios) đại diện cho các nhiễu động ξ :

- **Phụ tải:** Chèn nhiễu tương quan chuỗi thời gian (autocorrelated noise) để mô phỏng những ngày nóng bất thường hoặc lạnh cực đoan, cộng thêm nhiễu ngẫu nhiên từng giờ.
- **Điện mặt trời:** Mô phỏng hiệu ứng mây che phủ ngẫu nhiên kéo dài vài giờ làm giảm mạnh công suất.
- **Điện gió:** Thêm nhiễu ngẫu nhiên với độ trễ để mô phỏng các cơn gió giật hoặc hiện tượng lặng gió không dự báo trước.

Hàm mục tiêu được chuyển thành cực tiểu hóa giá trị kỳ vọng trên toàn bộ N kịch bản:

$$\mathbf{x}^* = \arg \min_{\mathbf{x}} \left(\alpha C_{\text{inv}}(\mathbf{x}) + \frac{1}{N} \sum_{i=1}^N \left[\alpha C_{\text{op}}^*(\mathbf{x}, \xi_i) + \beta S_{\text{total}}(\mathbf{x}, \xi_i) \right] \right) \quad (3.9)$$

Việc đánh giá ngẫu nhiên này bắt buộc tầng trên phải tìm kiếm các phương án đầu tư có đủ mức dự phòng để “sống sót” qua các tình huống xấu nhất, dù chi phí đầu tư ban đầu có thể cao hơn.

Chương 4

Phương pháp giải bài toán

Chương này trình bày các phương pháp được sử dụng để giải bài toán tối ưu hóa hộp đen ở tầng trên sau khi mô hình toán học đã được xác lập. Trọng tâm bao gồm các thuật toán AI, đặc tả môi trường tương tác cho học tăng cường, và quy trình phần mềm hiện thực hóa toàn bộ pipeline tính toán.

4.1 Phương pháp giải bài toán tối ưu hộp đen ở tầng trên

Việc giải quyết hàm hộp đen nhiều chiều có tính bất định cao là thách thức lớn. Đề tài đề xuất triển khai và so sánh hai phương pháp Trí tuệ nhân tạo tiên tiến để giải quyết bài toán tầng trên:

4.1.1 Tối ưu hóa Bayes (Bayesian Optimization - BO)

Tối ưu hóa Bayes đặc biệt hiệu quả với các hàm đánh giá chi phí cao (expensive-to-evaluate functions). Thay vì duyệt mù quáng, BO sử dụng thuật toán TPE (Tree-structured Parzen Estimator) qua thư viện Optuna để xây dựng mô hình xác suất học các vùng có tiềm năng tốt.

Quá trình hoạt động: Thuật toán xây dựng các phân phối xác suất dự đoán điểm phạt của các cấu hình đầu tư. Từ đó, hàm thu thập (Acquisition Function) sẽ tự động sinh ra tọa độ x tiếp theo cần được giải LP sao cho cân bằng giữa việc khai thác vùng đang có chi phí thấp nhất và khám phá những vùng không gian mới. Nhờ sự thông minh này, hệ thống chỉ cần khoảng 100 đến 200 lượt chạy mô phỏng (tương đương

100-200 vòng lặp LP) là có thể hội tụ nghiệm tối ưu, vượt trội hoàn toàn về tốc độ so với các phương pháp meta-heuristic truyền thống.

4.1.2 Học tăng cường (Reinforcement Learning - RL)

Hướng tiếp cận thứ hai là xây dựng hệ thống tác tử (Agent) thông qua Quá trình quyết định Markov (MDP) và huấn luyện bằng PPO / SAC sử dụng Stable-Baselines3.

Bài toán được cấu trúc thành môi trường tương tác (Gymnasium Environment):

- **Không gian trạng thái (State Space):** Tác tử quan sát hiện trạng hệ thống thông qua các đặc trưng đã chuẩn hóa: công suất hiện hữu tổng, phụ tải đỉnh, phụ tải trung bình và biên dự phòng (reserve margin) của từng vùng riêng biệt và tổng thể.
- **Không gian hành động (Action Space):** Hành động của tác tử trong một tập (episode) chính là xuất ra vectơ đầu tư liên tục $\mathbf{x} = [x_{z,k}]$.
- **Phần thưởng (Reward):** Hệ thống phản hồi lại cho tác tử giá trị phần thưởng tỉ lệ nghịch với điểm phạt: $r = -J(\mathbf{x})/10^6$. Nếu xảy ra cắt điện, điểm phạt J tăng vọt, phần thưởng rơi xuống mức âm sâu, khiến tác tử học được bài học phải xây đủ công suất để đảm bảo độ tin cậy.

Bằng cách huấn luyện qua hàng ngàn kịch bản (episodes), mạng nơ-ron của tác tử (Policy Network) sẽ liên kết được các đặc điểm hiện trạng của lưới điện với các hành động đầu tư tương ứng. So với BO, phương pháp RL tốn nhiều chi phí huấn luyện ban đầu hơn, nhưng mạng nơ-ron thu được lại có khả năng *suy luận siêu tốc (zero-shot inference)* khi phải đưa ra quyết định cho các hệ thống điện có đặc trưng tương tự trong tương lai.

4.2 Đặc tả môi trường tương tác cho bài toán học tăng cường

Để thuật toán Học tăng cường (PPO, SAC) có thể tương tác và học hỏi, toàn bộ hệ thống điện và bài toán tối ưu hai tầng được gói gọn lại thành một môi trường chuẩn hóa theo chuẩn **Gymnasium**.

4.2.1 Không gian quan sát

Thay vì để tác tử nhìn thấy toàn bộ ma trận dữ liệu khổng lồ của lưới điện, hệ thống trích xuất một vectơ trạng thái s chứa các đặc trưng cốt lõi mang tính tóm tắt và được chuẩn hóa về dải $[-1, 1]$:

- **Đặc trưng cấp vùng (Zonal Features):** Đối với mỗi vùng z , vectơ trạng thái chứa 4 giá trị:
 1. Công suất hiện hữu: $C_z^{\text{exist}}/C_{\text{max_sys}}$
 2. Phụ tải đỉnh: $D_z^{\text{peak}}/D_{\text{max_sys}}$
 3. Phụ tải trung bình: $\bar{D}_z/D_{\text{max_sys}}$
 4. Biên dự phòng (Reserve Margin): $(C_z^{\text{exist}} - D_z^{\text{peak}})/\max(1, D_z^{\text{peak}})$
- **Đặc trưng cấp hệ thống (Global Features):** Gồm 3 giá trị: Tổng công suất hệ thống, Tổng phụ tải đỉnh hệ thống, và Hệ số phụ tải (Load Factor).

Với hệ thống 3 vùng, vectơ trạng thái sẽ có độ dài là $3 \times 4 + 3 = 15$ chiều. Sự cô đọng này giúp mạng nơ-ron hội tụ nhanh hơn và giảm thiểu hiện tượng quá khớp (overfitting).

4.2.2 Không gian hành động và cơ chế phần thưởng

- **Hành động a :** Là vectơ công suất đầu tư liên tục, ví dụ với 3 vùng và 4 công nghệ, $a \in \mathbb{R}^{12}$. Tác tử sẽ đưa ra các giá trị trong giới hạn công suất cho phép (ví dụ: tối đa 2000 MW cho Điện mặt trời mỗi vùng).
- **Cơ chế phần thưởng (Reward Shaping):** Hàm phần thưởng được thiết kế trực tiếp từ hàm phạt tổng quát của bài toán (Phương trình

3.8):

$$r = -\frac{J(\mathbf{x})}{10^6} = -\frac{\alpha [C_{\text{inv}}(\mathbf{x}) + C_{\text{op}}^*(\mathbf{x})] + \beta \cdot S_{\text{total}}(\mathbf{x})}{10^6} \quad (4.1)$$

Việc chia cho 10^6 giúp chuẩn hóa thang đo của phần thưởng (từ hàng tỷ USD về mức một chữ số), giúp bộ tối ưu hóa Adam trong mạng nơ-ron hoạt động ổn định và không bị nổ gradient (gradient explosion).

4.3 Thiết kế hệ thống và quy trình triển khai tính toán

Để hiện thực hóa mô hình toán học trên thành một hệ thống mô phỏng và tối ưu hóa hoàn chỉnh, đề tài thiết kế một cấu trúc phần mềm (Software Pipeline) tự động với các phân hệ (modules) độc lập:

1. **Phân hệ Dữ liệu (Data Module):** Xử lý dữ liệu thô (chuỗi thời gian phụ tải, tham số mạng lưới) thành các cấu trúc dữ liệu đối tượng (SystemData, ZonalData). Tích hợp bộ sinh kịch bản ngẫu nhiên (ScenarioGenerator) để tạo ra đa dạng các mẫu thời tiết và phụ tải theo mô hình toán học tích hợp nhiễu (noise addition).
2. **Phân hệ Tầng dưới (Lower Level Module):** Đóng vai trò giải bài toán LP (Economic Dispatch). Phân hệ này sử dụng thư viện `scipy.optimize.linprog` với backend là bộ giải **HiGHS** – một trong những bộ giải mã nguồn mở tốt nhất hiện nay cho LP. Bằng cách chia nhỏ 8784 giờ thành các khối (batches) hoặc giải tuần tự, hệ thống đảm bảo tiêu thụ bộ nhớ tối thiểu.
3. **Phân hệ Tầng trên (Upper Level Module):** Tích hợp các thuật toán AI. Đối với BO, thư viện Optuna được sử dụng để chạy thuật toán TPE. Đối với RL, thư viện Stable-Baselines3 quản lý mạng nơ-ron Actor-Critic và thực thi việc tính toán gradient.

Đánh giá độ phức tạp thuật toán: Với hệ thống 3 vùng, mỗi giờ vận hành cần giải một bài toán LP có $N_{\text{var}} = N_{\text{gen}} + N_{\text{lines}} + N_{\text{zones}}$ biến. Khi chạy mô phỏng ngẫu nhiên (ví dụ 5 kịch bản Monte Carlo cho 8784 giờ), một lần đánh giá hàm mục tiêu ở tầng trên yêu cầu giải $5 \times 8784 = 43,920$ bài toán LP. Sự kết hợp giữa bộ giải HiGHS siêu tốc và số lượng

lần đánh giá giới hạn thông minh của Bayesian Optimization/RL chính là điểm tựa kỹ thuật giúp toàn bộ hệ thống khả thi trong thời gian chạy thực tế.

Tóm lại, cấu trúc lai hai tầng kết hợp giữa sự tối ưu linh hoạt không cần đạo hàm của AI ở tầng quyết định dài hạn (Upper Level) và sự chính xác toán học chặt chẽ của Quy hoạch tuyến tính ở tầng vận hành ngắn hạn (Lower Level) chính là chìa khóa để đề tài giải quyết trọn vẹn và thực tiễn bài toán GEP.

Chương 5

Kết quả thực nghiệm và thảo luận

Chương này tổng hợp các kết quả được sinh trực tiếp từ pipeline trong thư mục DATN/Code trên bốn kịch bản cấu hình: `wecc_3zone`, `wecc_clean_energy`, `wecc_future`, và `wecc_robust`. Mỗi thí nghiệm đều sử dụng dữ liệu WECC 3 vùng, mô phỏng 12 ngày đại diện (288 giờ), trong đó tầng trên dùng Bayesian Optimization còn tầng dưới giải bài toán điều độ kinh tế bằng LP với bộ giải HiGHS.

5.1 Thiết lập và tiêu chí đánh giá

Để bảo đảm tính so sánh, mỗi kịch bản đều được đánh giá theo cùng một quy trình hai bước. Thứ nhất, hệ thống chạy phương án *baseline* với vectơ đầu tư bằng 0 để đo chi phí vận hành và lượng cắt tải của lưới điện hiện hữu. Thứ hai, tầng trên tìm phương án đầu tư mới nhằm cực tiểu hóa hàm phạt tổng quát

$$J(\mathbf{x}) = C_{\text{inv}}(\mathbf{x}) + C_{\text{op}}^*(\mathbf{x}) + \beta S_{\text{total}}(\mathbf{x}), \quad (5.1)$$

trong đó C_{inv} là chi phí đầu tư niên kim hóa, C_{op}^* là chi phí vận hành tối ưu từ tầng dưới, và S_{total} là tổng điện năng bị cắt tải. Vì vậy, chỉ tiêu so sánh chính trong chương này là: tổng hàm phạt (tỷ USD), lượng cắt tải (GWh), và thời gian tối ưu hóa (giây).

5.2 So sánh định lượng giữa các kịch bản

Bảng 5.2.1 tóm tắt kết quả cuối cùng của bốn kịch bản. Có thể thấy ngay rằng kịch bản cơ sở không yêu cầu đầu tư thêm: phương án tốt nhất của Bayesian Optimization hội tụ về đúng nghiệm không đầu tư, cho cùng mức hàm phạt với baseline. Điều này cho thấy với tập 12 ngày đại diện đang xét, hệ thống hiện hữu vẫn đủ khả năng vận hành mà không cần mở rộng nguồn.

Bảng 5.2.1: So sánh baseline và phương án tối ưu Bayesian trên bốn kịch bản. Giá trị hàm phạt được chuẩn hóa theo tỷ USD, còn cắt tải được quy đổi về GWh.

Kịch bản	Baseline (tỷ USD)	BO (tỷ USD)	Giảm (%)	Shed base (GWh)	Shed BO (GWh)	Thời gian (s)
Cơ sở	0.033	0.033	0.0	0.0	0.0	53.7
Chuyển dịch xanh	7.584	4.369	42.4	349.4	103.0	25.6
Tương lai căng thẳng	15.607	8.706	44.2	767.3	319.1	26.2
Quy hoạch robust	3.107	2.414	22.3	140.5	141.9	60.3


Hai kịch bản tạo ra mức cải thiện mạnh nhất là *Chuyển dịch xanh* và *Tương lai căng thẳng*. Ở kịch bản chuyển dịch xanh, tổng hàm phạt giảm 42.4% còn cắt tải giảm từ 349.4 GWh xuống 103.0 GWh, tương đương mức giảm 70.5%. Ở kịch bản tương lai căng thẳng, mức cải thiện về hàm phạt đạt 44.2%, trong khi cắt tải giảm từ 767.3 GWh xuống 319.1 GWh, tức giảm khoảng 58.4%. Điều này xác nhận kiến trúc hai tầng có khả năng tự động phân bổ đầu tư đúng vào các công nghệ và vùng còn thiếu hụt công suất nhất.

Ngược lại, kịch bản robust cho thấy một dạng đánh đổi khác: hàm phạt kỳ vọng vẫn giảm 22.3%, nhưng lượng cắt tải trên tập ngày đại diện tăng nhẹ từ 140.5 GWh lên 141.9 GWh. Kết quả này phù hợp với cách xây dựng bài toán robust: tầng trên không tối ưu cho duy nhất một quỹ đạo phụ tải-tái tạo cố định, mà tối ưu theo kỳ vọng trên nhiều kịch bản nhiễu Monte Carlo. Vì vậy, nghiệm robust có thể hy sinh một phần hiệu năng trên bộ dữ liệu đại diện để đổi lấy tính bền vững cao hơn trước bất định.


5.3 Phân tích cơ cấu đầu tư tối ưu

Hình 5.3.1 thể hiện phân bổ công suất đầu tư theo từng vùng và công nghệ. Kịch bản chuyển dịch xanh ưu tiên mở rộng rất mạnh điện gió và pin lưu trữ, với tổng mức đầu tư lần lượt khoảng 8.48 GW gió và 3.41 GW pin, trong khi điện mặt trời chỉ tăng 0.70 GW. Điều này phản ánh tác động của hệ số phát thải và mức thuế carbon cao: mô hình ưu tiên các nguồn tái tạo có sản lượng cao và dùng pin để bù độ biến thiên theo thời gian.


Trong kịch bản tương lai căng thẳng, danh mục đầu tư tối ưu mở rộng đồng thời cả bốn công nghệ, nổi bật là 8.60 GW điện gió, 4.71 GW điện mặt trời và 3.20 GW pin. So với kịch bản chuyển dịch xanh, phương án này phân bổ nhiều hơn cho điện mặt trời và pin do phụ tải tăng mạnh trên toàn hệ thống. Trong khi đó, kịch bản robust lại nghiêng nhiều hơn về nguồn điều độ được, với 2.51 GW gas_ccs và 1.97 GW pin, cho thấy khi đưa bất định vào hàm mục tiêu thì giá trị của công suất chắc chắn và khả năng dịch chuyển năng lượng tăng lên rõ rệt.



(a) Kịch bản chuyển dịch xanh



(b) Kịch bản tương lai căng thẳng




(c) Kịch bản robust

Hình 5.3.1: Phân bổ công suất đầu tư tối ưu theo vùng và công nghệ cho ba kịch bản cần mở rộng nguồn.

5.4 Hành vi hội tụ của Bayesian Optimization

Hình 5.4.1 cho thấy tiến trình hội tụ của Bayesian Optimization trong hai trường hợp đại diện. Với kịch bản chuyển dịch xanh, đường bao tốt nhất giảm khá nhanh chỉ sau khoảng 40–50 lượt đánh giá, phản ánh rằng cấu trúc hàm mục tiêu tuy phi lồi nhưng vẫn đủ trơn để bộ tìm kiếm TPE khai thác hiệu quả. Với kịch bản robust, hội tụ chậm hơn đáng kể và thời gian chạy tăng lên hơn 60 giây do mỗi lần đánh giá phải lấy trung bình trên nhiều kịch bản Monte Carlo.



Hình 5.4.1: Đường hội tụ của Bayesian Optimization cho hai kịch bản tiêu biểu.

Tổng hợp lại, các kết quả thực nghiệm cho thấy mô hình Bi-level Hybrid thực sự có giá trị trong các bối cảnh hệ thống bị siết chặt bởi chính sách carbon, tăng trưởng phụ tải hoặc bất định tái tạo. Khi hệ thống hiện hữu vẫn đủ dự phòng, mô hình không buộc phải đầu tư thêm; ngược lại, khi xuất hiện thiếu hụt cấu trúc, pipeline sẽ tự động đề xuất một tổ hợp nguồn mới với vai trò rất rõ ràng giữa nhóm năng lượng tái tạo, pin lưu trữ và nguồn điều độ được.

Tài liệu tham khảo

- [1] J. Bergstra, R. Bardenet, Y. Bengio, and B. Kégl. Algorithms for hyper-parameter optimization. In *Advances in Neural Information Processing Systems*, volume 24, 2011.
- [2] D. Bertsimas and J. N. Tsitsiklis. *Introduction to Linear Optimization*. Athena Scientific, 1997.
- [3] R. A. Brealey, S. C. Myers, and F. Allen. *Principles of Corporate Finance*. McGraw-Hill Education, 13th edition, 2020.
- [4] B. Colson, P. Marcotte, and G. Savard. An overview of bilevel optimization. *Annals of Operations Research*, 153(1):235–256, 2007. doi: 10.1007/s10479-007-0176-2.
- [5] G. B. Dantzig. Maximization of a linear function of variables subject to linear inequalities. *Activity Analysis of Production and Allocation*, pages 339–347, 1951.
- [6] P. I. Frazier. A tutorial on Bayesian optimization. *arXiv preprint arXiv:1807.02811*, 2018.
- [7] T. Haarnoja, A. Zhou, P. Abbeel, and S. Levine. Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor. In *Proceedings of the 35th International Conference on Machine Learning (ICML)*, pages 1861–1870, 2018.
- [8] T. Haarnoja, A. Zhou, K. Hartikainen, G. Tucker, S. Ha, J. Tan, V. Kumar, H. Zhu, A. Gupta, P. Abbeel, and S. Levine. Soft actor-critic algorithms and applications. *arXiv preprint arXiv:1812.05905*, 2018.

- [9] P. Hansen, B. Jaumard, and G. Savard. New branch-and-bound rules for linear bilevel programming. *SIAM Journal on Scientific and Statistical Computing*, 13(5):1194–1217, 1992. doi: 10.1137/0913069.
- [10] D. R. Jones, M. Schonlau, and W. J. Welch. Efficient global optimization of expensive black-box functions. *Journal of Global Optimization*, 13(4):455–492, 1998. doi: 10.1023/A:1008306431147.
- [11] N. Karmarkar. A new polynomial-time algorithm for linear programming. *Combinatorica*, 4(4):373–395, 1984. doi: 10.1007/BF02579150.
- [12] N. E. Koltsaklis and A. S. Dagoumas. State-of-the-art generation expansion planning: A review. *Applied Energy*, 230:563–589, 2018. doi: 10.1016/j.apenergy.2018.08.087.
- [13] National Renewable Energy Laboratory. 2024 annual technology baseline. Technical report, National Renewable Energy Laboratory, Golden, CO, 2024. URL <https://atb.nrel.gov/>.
- [14] V. Oree, S. Z. Sayed Hassen, and P. J. Fleming. Generation expansion planning optimisation with renewable energy integration: A review. *Renewable and Sustainable Energy Reviews*, 69:790–803, 2017. doi: 10.1016/j.rser.2016.11.120.
- [15] M. L. Puterman. *Markov Decision Processes: Discrete Stochastic Dynamic Programming*. John Wiley & Sons, 1994.
- [16] C. E. Rasmussen and C. K. I. Williams. *Gaussian Processes for Machine Learning*. MIT Press, 2006.
- [17] R. Y. Rubinstein and D. P. Kroese. *Simulation and the Monte Carlo Method*. John Wiley & Sons, 3rd edition, 2016.
- [18] H. Sadeghi, M. Rashidinejad, and A. Abdollahi. A comprehensive sequential review study through the generation expansion planning. *Renewable and Sustainable Energy Reviews*, 67:1369–1394, 2017. doi: 10.1016/j.rser.2016.09.046.

- [19] J. Schulman, S. Levine, P. Abbeel, M. Jordan, and P. Moritz. Trust region policy optimization. In *Proceedings of the 32nd International Conference on Machine Learning (ICML)*, pages 1889–1897, 2015.
- [20] J. Schulman, P. Moritz, S. Levine, M. Jordan, and P. Abbeel. High-dimensional continuous control using generalized advantage estimation. *arXiv preprint arXiv:1506.02438*, 2015.
- [21] J. Schulman, F. Wolski, P. Dhariwal, A. Radford, and O. Klimov. Proximal policy optimization algorithms. *arXiv preprint arXiv:1707.06347*, 2017.
- [22] B. Shahriari, K. Swersky, Z. Wang, R. P. Adams, and N. de Freitas. Taking the human out of the loop: A review of Bayesian optimization. *Proceedings of the IEEE*, 104(1):148–175, 2016. doi: 10.1109/JPROC.2015.2494218.
- [23] A. Sinha, P. Malo, and K. Deb. A review on bilevel optimization: From classical to evolutionary approaches and applications. *IEEE Transactions on Evolutionary Computation*, 22(2):276–295, 2018. doi: 10.1109/TEVC.2017.2712906.
- [24] R. S. Sutton and A. G. Barto. *Reinforcement Learning: An Introduction*. MIT Press, 2nd edition, 2018.
- [25] A. J. Wood, B. F. Wollenberg, and G. B. Sheblé. *Power Generation, Operation, and Control*. John Wiley & Sons, 3rd edition, 2013.
- [26] Q. Zhang and F. Li. A dataset for electricity market studies on western and northeastern power grids in the united states. *Scientific Data*, 10(1):646, Sep 2023. doi: 10.1038/s41597-023-02448-w. URL <https://doi.org/10.1038/s41597-023-02448-w>.