

ĐẠI HỌC BÁCH KHOA HÀ NỘI

ĐỒ ÁN II

**VRAE: Cải tiến bộ mã hóa tự động
khử nhiễu và khử mờ cho biển số xe**

NGUYỄN TẤT CƯỜNG

cuong.nt227090@sis.hust.edu.vn

Chuyên ngành: Toán Tin

Giảng viên hướng dẫn : TS. Trần Ngọc Thắng

Bộ môn : Toán Tin

Khoa : Khoa Toán Tin

Chữ ký GVHD

Hà Nội, 10-2025

NHẬN XÉT CỦA GIẢNG VIÊN HƯỚNG DẪN

1. Mục tiêu và nội dung của đề án

(a) Mục tiêu:

(b) Nội dung:

2. Kết quả đạt được

3. Ý thức làm việc của sinh viên

Hà Nội, ngày tháng năm 2025
Giảng viên hướng dẫn

TS. Trần Ngọc Thăng

Lời cảm ơn

Em xin chân thành cảm ơn TS. Nguyễn Nam Phong và TS. Trần Ngọc Thăng đã tận tình hướng dẫn, chỉ bảo và tạo điều kiện thuận lợi cho em trong suốt quá trình thực hiện đồ án này. Những góp ý quý báu của các thầy đã giúp em hoàn thiện nghiên cứu và nâng cao chất lượng đồ án.

Em cũng xin gửi lời cảm ơn sâu sắc đến các đồng nghiệp tại Aithings đã luôn đồng hành, hỗ trợ và chia sẻ kinh nghiệm quý báu trong suốt thời gian thực hiện đồ án. Sự giúp đỡ nhiệt tình của mọi người đã tạo động lực to lớn giúp em vượt qua những khó khăn và hoàn thành tốt đồ án này.

Cuối cùng, em xin cảm ơn gia đình, bạn bè đã luôn động viên, ủng hộ và tạo điều kiện tốt nhất để em có thể hoàn thành chương trình học tập.

Hà Nội, tháng năm 2025
Tác giả đồ án

Nguyễn Tất Cường

Lời nói đầu

Đồ án này là một bài nghiên cứu tập trung vào việc phát triển và thực nghiệm phương pháp **VRAE** (Vertical Residual Autoencoder) nhằm giải quyết bài toán khử nhiễu và khử mờ cho biển số xe. Đây là kết quả nghiên cứu chính trong bài báo khoa học có tiêu đề “*VRAE: Vertical Residual Autoencoder for License Plate Denoising and Deblurring*” do em làm tác giả chính.

Nghiên cứu này đã được chấp nhận trình bày tại Hội nghị Quốc tế về Công nghệ Thông tin và Truyền thông lần thứ 14 (**SOICT 2025**). Đồ án tập trung vào việc tối ưu hóa kiến trúc Autoencoder bằng cách tích hợp các kết nối dư dọc (Vertical Residual) để bảo toàn chi tiết vi mô và cải thiện hiệu suất khôi phục ảnh biển số xe trong các điều kiện chất lượng thấp.

Mục lục

DANH SÁCH HÌNH VẼ	2
DANH SÁCH BẢNG	4
1 Cơ sở LÝ THUYẾT	5
1.1 Tổng quan bài toán về thị giác máy tính	5
1.2 Mạng nơ-ron nhân tạo	6
1.3 Mạng nơ-ron tích chập	7
1.3.1 Ảnh màu RGB	7
1.3.2 Lớp tích chập	8
1.3.3 Tích chập chuyển vị	9
1.3.4 Lớp pooling	9
1.3.5 Hàm kích hoạt ReLU	11
1.4 Kiến trúc mô hình ResNet-50	12
1.5 Lý thuyết về Entropy và ứng dụng trong mạng nơ-ron tích chập	13
1.5.1 Lý thuyết Entropy	13
1.5.2 Sự Thay đổi Entropy trong lớp tích chập	13
1.6 Phương pháp Autoencoder	15
1.7 Phương pháp GAN	16
1.8 Phương pháp Flow-based	17
2 BÀI TOÁN KHỬ NHIỀU VÀ KHỬ MỜ CHO ẢNH PHƯƠNG TIỆN CÓ BIỂN SỐ XE	20
2.1 Giới thiệu	20
2.2 Phát biểu bài toán	21
2.3 Khoảng trống nghiên cứu	22
3 PHƯƠNG PHÁP VRAE: VERTICAL RESIDUAL AUTOENCODER	23
3.1 Tổng quan kiến trúc	23
3.1.1 Khối chính (Main Block)	24
3.1.2 Khối hỗ trợ (Auxiliary Block)	24
3.1.3 Bộ giải mã (Decoder)	25
3.2 Chuẩn bị dữ liệu	25
3.3 Lựa chọn cấu hình kiến trúc	26
4 KẾT QUẢ VÀ THẢO LUẬN	29

4.1	Đánh giá định lượng	29
4.2	Phân tích bảo toàn nội dung thông tin	30
4.3	Phân tích sự đánh đổi (Trade-offs)	31
4.4	Hướng phát triển trong tương lai	31
4.5	Kết luận	32
MINH CHỨNG		33
TÀI LIỆU THAM KHẢO		34

Danh sách hình vẽ

1.2.1 Kiến trúc ANN	6
1.3.1 Ảnh màu RGB	8
1.3.2 Lớp tích chập trong trích xuất đặc trưng	8
1.3.3 Cách tính tích chập chuyển vị	9
1.3.4 Lớp pooling trong mạng nơ-ron tích chập	10
1.3.5 Hàm kích hoạt ReLU	12
1.6.1 Kiến trúc Autoencoder	15
1.7.1 Kiến trúc GAN	16
1.8.1 Kiến trúc Flow based	18
3.1.1 Kiến trúc phương pháp VRAE	23
4.2.1 Sự thay đổi Entropy trung bình qua các lớp mã hóa của AE và VRAE.	30
4.3.1 Trục quan hóa sự đánh đổi giữa hiệu suất tái tạo (NMSE, PSNR, SSIM) và tốc độ suy luận (FPS) thông qua mặt tiền Pareto.	31
4.5.1 Giấy chứng nhận tham dự và trình bày tại SOICT 2025	33

Danh sách bảng

4.1.1 So sánh định lượng giữa GAN, FB, AE và phương pháp VRAE đề xuất trên tập kiểm tra (Test set).	29
--	----

Chương 1

Cơ sở lý thuyết

1.1 Tổng quan bài toán về thị giác máy tính

Thị giác máy tính (Computer Vision) là một lĩnh vực quan trọng của trí tuệ nhân tạo (AI), tập trung vào việc giúp máy tính hiểu, phân tích và diễn giải thông tin từ hình ảnh hoặc video. Mục tiêu của thị giác máy tính là mô phỏng khả năng quan sát và nhận thức của con người để trích xuất thông tin hữu ích phục vụ cho các ứng dụng như giám sát tự động, lái xe tự hành, y học chẩn đoán hình ảnh, hay tương tác người-máy.

Trong lĩnh vực này, có một số bài toán cơ bản và quan trọng như sau:

Phân loại ảnh (Image Classification):

Đây là bài toán gán một hoặc nhiều nhãn cho một bức ảnh dựa trên nội dung của nó. Mô hình được huấn luyện để nhận diện các đặc trưng phân biệt giữa các lớp ảnh. Các kiến trúc mạng nơ-ron tích chập (CNN) nổi bật như VGG, ResNet, DenseNet và EfficientNet đã đạt được những kết quả vượt trội trong bài toán này.

Nhận diện đối tượng (Object Detection):

Bài toán này không chỉ yêu cầu xác định loại đối tượng trong ảnh mà còn phải dự đoán vị trí của chúng thông qua các hộp giới hạn (bounding boxes). Các mô hình hiện đại như YOLO (You Only Look Once), SSD (Single Shot MultiBox Detector), và Faster R-CNN đã thể hiện hiệu quả cao cả về độ chính xác và tốc độ.

Phân đoạn ảnh (Image Segmentation):


Phân đoạn ảnh là quá trình chia ảnh thành các vùng có ý nghĩa, trong đó mỗi pixel được gán nhãn tương ứng với một đối tượng hoặc vùng cụ thể. Bài toán này cho phép mô hình hiểu cấu trúc chi tiết hơn trong ảnh so với nhận diện đối tượng. Một số mô hình tiêu biểu là U-Net, DeepLab và Mask R-CNN.

Các bài toán nâng cao khác:

Ngoài ba hướng trên, thị giác máy tính còn bao gồm nhiều bài toán khác như tái tạo ảnh 3D, ước lượng độ sâu, theo dõi đối tượng (object tracking), tăng cường ảnh (image enhancement) và sinh ảnh mới từ mô tả (text-to-image generation). Các bài toán này thường yêu cầu sự kết hợp giữa các mô hình học sâu và các kỹ thuật biểu diễn đặc trưng (feature representation) trong không gian tiềm ẩn (latent space).

1.2 Mạng nơ-ron nhân tạo

Mạng thần kinh nhân tạo (Artificial Neural Networks - ANN) là một mô hình tính toán lấy cảm hứng từ cách hoạt động của hệ thần kinh sinh học, đặc biệt là cấu trúc và chức năng của não bộ con người. ANN bao gồm các đơn vị tính toán gọi là nơ-ron nhân tạo, được kết nối với nhau theo nhiều tầng để xử lý thông tin và học từ dữ liệu.



Hình 1.2.1: Kiến trúc ANN

Một ANN thông thường bao gồm các thành phần chính sau :

- **Tầng đầu vào :** Nhận dữ liệu đầu vào, có thể là hình ảnh, văn bản, âm thanh hoặc các dạng dữ liệu khác.
- **Tầng ẩn :** Bao gồm nhiều nơ-ron xử lý dữ liệu, áp dụng các phép toán và hàm kích hoạt để trích xuất đặc trưng từ dữ liệu.
- **Tầng đầu ra :** Tạo ra kết quả cuối cùng, có thể là nhãn phân loại, giá trị dự đoán, hoặc các thông tin khác tùy vào bài toán.

Nguyên lý hoạt động : Mỗi kết nối giữa các nơ-ron có một trọng số (weight) xác định mức độ ảnh hưởng của tín hiệu truyền qua. Khi dữ liệu đầu vào đi qua mạng, nó được tính toán qua các trọng số, cộng thêm một số bù (bias), và đi qua một hàm kích hoạt (activation function) để tạo ra đầu ra phi tuyến tính. Quá trình học của mạng thần kinh là tối ưu hóa các trọng số này thông qua các thuật toán như Lan truyền

ngược (backpropagation) và Tối ưu hóa bằng lan truyền gradient (gradient descent).

1.3 Mạng nơ-ron tích chập

Mạng nơ-ron tích chập là một loại mạng nơ-ron nhân tạo chuyên xử lý dữ liệu dạng lưới, đặc biệt hiệu quả với ảnh và video. CNN mô phỏng cách hoạt động của vỏ não thị giác trong não người, giúp máy tính nhận diện và phân loại hình ảnh.

Khi xử lý ảnh màu RGB, CNN sử dụng các lớp tích chập để trích xuất đặc trưng. Ảnh đầu vào có ba kênh màu đỏ, lục, lam, được biểu diễn dưới dạng một tensor 3 chiều chiều cao, chiều rộng, số kênh. Mỗi bộ lọc trong lớp tích chập sẽ trượt qua ảnh, tính toán tích chập với từng kênh màu, sau đó tổng hợp kết quả để tạo ra một bản đồ đặc trưng.

Các lớp tích chập liên tiếp giúp mạng phát hiện các đặc trưng quan trọng như cạnh, góc, kết cấu và hình dạng. Tiếp theo, các lớp pooling giúp giảm kích thước dữ liệu, tăng hiệu quả tính toán. Cuối cùng, các lớp kết nối đầy đủ fully connected xử lý thông tin để thực hiện phân loại hoặc nhận diện đối tượng. Nhờ cơ chế này, CNN trở thành mô hình mạnh mẽ trong các ứng dụng như nhận diện khuôn mặt, phát hiện vật thể và phân loại hình ảnh.


1.3.1 Ảnh màu RGB

Ảnh màu RGB là một loại hình ảnh kỹ thuật số được biểu diễn bằng ba kênh màu cơ bản: Đỏ (Red - R), Xanh lá (Green - G) và Xanh dương (Blue - B). Hệ màu này dựa trên mô hình tổng hợp màu cộng (Additive Color Model), trong đó ba màu cơ bản được kết hợp với nhau theo các cường độ khác nhau để tạo ra nhiều màu sắc khác nhau.

Mỗi điểm ảnh (pixel) trong ảnh RGB được biểu diễn bằng một bộ ba giá trị tương ứng với cường độ sáng của từng kênh màu, thường có giá trị trong khoảng từ 0 đến 255 đối với ảnh 8-bit. Khi cả ba kênh đều đạt giá trị tối đa (255, 255, 255), điểm ảnh sẽ hiển thị màu trắng; khi cả ba kênh đều bằng 0 (0, 0, 0), điểm ảnh sẽ có màu đen. Sự thay đổi cường độ giữa ba kênh này cho phép tái tạo hàng triệu màu sắc khác nhau, tạo nên hình ảnh đa dạng và sinh động.

Trong xử lý ảnh, ảnh RGB thường được sử dụng như dữ liệu đầu vào cho các thuật toán nhận dạng, phân loại hoặc phát hiện đối tượng. Tuy nhiên, vì mỗi pixel chứa nhiều thông tin màu sắc, các kỹ thuật tiền xử lý như chuyển đổi ảnh về không gian màu khác (ví dụ: Grayscale,

HSV) hoặc tách riêng từng kênh màu thường được áp dụng nhằm giảm độ phức tạp tính toán và tăng hiệu quả cho bài toán cụ thể.




Hình 1.3.1: Ảnh màu RGB

1.3.2 Lớp tích chập

Lớp tích chập là thành phần cốt lõi của mạng nơ-ron tích chập, một mô hình chuyên dụng trong xử lý ảnh và thị giác máy tính. Lớp này có nhiệm vụ trích xuất đặc trưng từ ảnh bằng cách áp dụng các bộ lọc (kernels/filters) để phát hiện các mẫu như cạnh, góc, hình dạng hoặc kết cấu.

Cụ thể, mỗi bộ lọc trong lớp tích chập sẽ trượt trên toàn bộ ảnh đầu vào, thực hiện phép nhân điểm từng phần tử và tổng hợp lại thành một giá trị duy nhất, tạo ra một bản đồ đặc trưng cho mỗi bộ lọc. Các bộ lọc này ban đầu có trọng số ngẫu nhiên và được tối ưu hóa trong quá trình huấn luyện thông qua thuật toán lan truyền ngược nhằm học ra những mẫu quan trọng nhất cho bài toán.

Nhờ khả năng học các đặc trưng không cần thiết kể thủ công, lớp tích chập giúp mạng nơ-ron tự động phát hiện các yếu tố từ đơn giản (như đường biên) đến phức tạp (như cấu trúc đối tượng) qua nhiều tầng tích chập liên tiếp. Đây chính là lý do mạng nơ-ron tích chập đạt hiệu quả vượt trội trong các bài toán nhận dạng hình ảnh, phân loại ảnh, phát hiện đối tượng và nhiều ứng dụng thị giác máy tính khác.



Hình 1.3.2: Lớp tích chập trong trích xuất đặc trưng

Cách hoạt động của lớp tích chập:

1. Duyệt một bộ lọc nhỏ qua từng vùng trên ảnh đầu vào

2. Nhân từng giá trị của bộ lọc với giá trị tương ứng của ảnh, sau đó cộng lại để tạo ra giá trị mới
3. Kết quả là một ma trận đầu ra (feature map) chứa các đặc trưng quan trọng của ảnh

Công thức tích chập giữa ảnh đầu vào I và bộ lọc K :

$$O(x, y) = \sum_i \sum_j I(x + i, y + j) \cdot K(i, j)$$

Trong đó :


- $O(x, y)$ là giá trị tại tọa độ (x, y) của ảnh
- $I(x + i, y + j)$ là giá trị điểm ảnh đầu vào
- $K(i, j)$ là giá trị của bộ lọc

1.3.3 Tích chập chuyển vị

Trong các mạng CNN, phép tích chập thường làm giảm kích thước không gian của đặc trưng. Ngược lại, tích chập chuyển vị giúp tăng kích thước đặc trưng, hữu ích trong các bài toán như phân đoạn ảnh hoặc siêu phân giải.

Về nguyên lý, tích chập chuyển vị chèn các giá trị zero giữa các pixel của đầu vào và thực hiện convolution với kernel, cho phép mở rộng không gian mà vẫn học được các trọng số thích nghi. Nếu đầu vào có kích thước n , kernel kích thước k , stride s và padding p , kích thước đầu ra là:

$$n_{out} = (n - 1) \times s - 2p + k$$



Hình 1.3.3: Cách tính tích chập chuyển vị

1.3.4 Lớp pooling


Lớp pooling là một thành phần quan trọng trong mạng nơ-ron tích chập, giúp giảm kích thước của dữ liệu đầu ra từ lớp tích chập, đồng

thời giữ lại các đặc trưng quan trọng. Lớp này giúp tăng hiệu quả tính toán, giảm số lượng tham số và hạn chế tình trạng overfitting.

Có hai loại pooling phổ biến là max pooling và average pooling. Trong đó, max pooling chọn giá trị lớn nhất trong mỗi vùng nhỏ của ảnh đầu vào, giúp làm nổi bật các đặc trưng mạnh nhất như cạnh hoặc điểm nổi bật. Average pooling thì tính giá trị trung bình trong vùng đó, giúp làm mượt đặc trưng và giữ lại thông tin tổng quát.

Pooling còn có vai trò tạo ra sự bất biến đối với dịch chuyển nhỏ của đối tượng trong ảnh. Điều này có nghĩa là, nếu đối tượng trong ảnh bị dịch nhẹ sang trái, phải, lên hoặc xuống thì đặc trưng trích xuất sau lớp pooling vẫn không thay đổi nhiều. Nhờ đó, mô hình trở nên ổn định và chính xác hơn trong thực tế.

Thông thường, lớp pooling được đặt sau một hoặc nhiều lớp tích chập, và lặp lại nhiều lần trong toàn bộ kiến trúc của mạng để dần giảm kích thước không gian của ảnh đầu vào trong khi vẫn giữ được thông tin cần thiết cho việc phân loại hoặc nhận dạng.



Hình 1.3.4: Lớp pooling trong mạng nơ-ron tích chập

Cách hoạt động của lớp pooling:

1. Chia ma trận đầu vào thành các vùng nhỏ không trùng lặp
2. Áp dụng phép toán (max pooling hoặc average pooling) lên từng vùng để lấy giá trị đại diện
3. Kết quả là một ma trận có kích thước nhỏ hơn nhưng vẫn giữ được các đặc trưng quan trọng

Công thức của max pooling trên vùng kích thước $k \times k$ được biểu diễn như sau:

$$O(x, y) = \max_{i=0}^{k-1} \max_{j=0}^{k-1} I(x + i, y + j)$$

Trong đó:

- $O(x, y)$ là giá trị tại tọa độ (x, y) của ma trận đầu ra.

- $I(x + i, y + j)$ là giá trị điểm ảnh đầu vào trong cửa sổ pooling.

1.3.5 Hàm kích hoạt ReLU

Hàm kích hoạt ReLU (Rectified Linear Unit) được sử dụng rộng rãi trong các mạng nơ-ron tích chập nhờ tính đơn giản và hiệu quả trong việc huấn luyện các mô hình sâu. ReLU được định nghĩa như sau:

$$\text{ReLU}(x) = \max(0, x)$$

Trong mạng CNN, ReLU thường được áp dụng ngay sau mỗi lớp tích chập. Vai trò của nó là **giới thiệu tính phi tuyến (non-linearity)** vào mô hình, cho phép mạng học được các biểu diễn phức tạp hơn của dữ liệu đầu vào. Nếu chỉ sử dụng các phép tích chập tuyến tính mà không có hàm kích hoạt phi tuyến, toàn bộ mạng sẽ chỉ tương đương với một phép biến đổi tuyến tính duy nhất, khiến khả năng biểu diễn của mạng bị hạn chế.

Ý nghĩa của ReLU trong CNN


- **Tăng tốc huấn luyện:** ReLU giúp mạng hội tụ nhanh hơn so với các hàm kích hoạt truyền thống như sigmoid hay tanh, nhờ gradient không bị bão hòa trong vùng dương.
- **Giảm hiện tượng vanishing gradient:** Trong khi sigmoid/tanh làm gradient nhỏ dần khi lan truyền ngược qua nhiều lớp, ReLU giữ gradient = 1 với giá trị dương, giúp tín hiệu học được duy trì sâu trong mạng.
- **Tạo đặc trưng thưa (sparse feature map):** Với các giá trị âm bị triệt tiêu về 0, ReLU làm cho các feature map có nhiều phần tử bằng 0, giúp giảm tương quan giữa các đặc trưng và tăng tính khái quát hóa.

Hạn chế và giải pháp: Một nhược điểm phổ biến của ReLU trong CNN là hiện tượng **“ReLU chết” (Dead ReLU)**, xảy ra khi một neuron luôn nhận giá trị âm nên đầu ra luôn bằng 0, không thể học được nữa. Để khắc phục, các biến thể như **Leaky ReLU**, **PReLU**, hoặc **ELU** thường được sử dụng.

Vị trí của ReLU trong kiến trúc CNN ReLU thường được đặt:

- Sau mỗi lớp tích chập (Conv + ReLU)
- Sau mỗi lớp fully-connected (Linear + ReLU)

- Kết hợp với Batch Normalization để ổn định huấn luyện và tránh mất cân bằng giá trị đầu ra



Hình 1.3.5: Hàm kích hoạt ReLU

1.4 Kiến trúc mô hình ResNet-50

ResNet-50 là mạng nơ-ron tích chập sâu gồm 50 lớp, được xây dựng dựa trên các residual block nhằm giải quyết vấn đề suy giảm gradient khi huấn luyện mạng sâu. Kiến trúc ResNet-50 được chia thành các stage chính như sau:

- **Stage 1 (Stem):** Gồm một lớp tích chập 7×7 với stride 2, theo sau là Batch Normalization, ReLU và Max Pooling 3×3 . Stage này có nhiệm vụ trích xuất đặc trưng mức thấp từ ảnh đầu vào.
- **Stage 2 (Conv2_x):** Bao gồm 3 residual bottleneck blocks. Mỗi block sử dụng cấu trúc $1 \times 1 \rightarrow 3 \times 3 \rightarrow 1 \times 1$, với số kênh đầu ra là 256.
- **Stage 3 (Conv3_x):** Gồm 4 bottleneck blocks, tăng số kênh lên 512 và giảm kích thước không gian thông qua stride 2 ở block đầu tiên.
- **Stage 4 (Conv4_x):** Bao gồm 6 bottleneck blocks, là stage sâu nhất của ResNet-50, với số kênh đầu ra là 1024.
- **Stage 5 (Conv5_x):** Gồm 3 bottleneck blocks cuối cùng, mở rộng số kênh lên 2048 để trích xuất đặc trưng mức cao.

Cuối mạng là lớp Global Average Pooling và một lớp Fully Connected, thường được sử dụng cho bài toán phân loại. Trong các bài toán thị giác máy tính như Super Resolution, phần backbone ResNet-50 thường được sử dụng đến một stage nhất định để trích xuất đặc trưng [5].

1.5 Lý thuyết về Entropy và ứng dụng trong mạng nơ-ron tích chập

1.5.1 Lý thuyết Entropy

Định nghĩa Entropy: Theo lý thuyết thông tin của Shannon [11], entropy là một đại lượng đo lường lượng thông tin hoặc độ bất định của một biến ngẫu nhiên. Đối với một biến ngẫu nhiên liên tục X trong không gian $\mathbb{R}^d$ với hàm mật độ xác suất (pdf) f , **entropy vi phân** (differential entropy) được định nghĩa là:

$$H(X) = \mathbb{E}[-\log f(X)] \quad (1.1)$$

Công trình của Cover và Thomas [1] đã cung cấp nền tảng toán học vững chắc cho việc ứng dụng lý thuyết thông tin vào các lĩnh vực khác nhau, bao gồm cả học máy.

Ý nghĩa của Entropy trong Mạng Neural: Trong bối cảnh của mạng neural, entropy của một tensor ẩn (hidden tensor) đại diện cho **mức độ đa dạng và phong phú của thông tin** mà tensor đó mang theo [4, 9]:

- **Entropy cao:** Dữ liệu rất đa dạng và chi tiết, chứa đựng nhiều thông tin phong phú [10]. Biểu diễn này có nhiều trạng thái khả dĩ khác nhau.
- **Entropy thấp:** Dữ liệu trở nên tập trung hơn vào các đặc điểm chính, và do đó kém đa dạng hơn [12]. Thông tin đã được nén lại hoặc lọc bớt, thường tập trung vào các đặc trưng quan trọng nhất cho tác vụ.

Việc theo dõi sự thay đổi của entropy khi dữ liệu truyền qua các lớp của mạng cho phép chúng ta hiểu được **cách mạng xử lý và chuyển hóa thông tin** [3].

1.5.2 Sự Thay đổi Entropy trong lớp tích chập

Công thức tính toán: Một đóng góp quan trọng của bài báo [9] là biến đổi phép tích chập 2D thành một phép nhân ma trận-vector. Bằng cách "làm phẳng" (flatten) ảnh đầu vào X thành vector X_F và xây dựng một ma trận C_M đặc biệt từ bộ lọc tích chập C , phép tích chập có thể được biểu diễn dưới dạng $Z_F = C_M X_F$.

Sự thay đổi entropy khi áp dụng một bộ lọc tích chập C kích thước $p \times q$ lên một đầu vào 2D X kích thước $l \times w$ được tính bằng công thức

sau [9]:

$$\Delta H_{\text{conv}} = (l - p + 1)(w - q + 1) \log(|c_{11}|) \quad (1.2)$$

Trong đó c_{11} là **trọng số ở góc trên bên trái** của bộ lọc tích chập.

Phân tích ý nghĩa và ảnh hưởng đến thông tin: Công thức (2) cho thấy sự thay đổi entropy **không phụ thuộc vào giá trị đầu vào X** , mà chỉ phụ thuộc vào kích thước và một trọng số cụ thể của bộ lọc [9]. Điều này có ý nghĩa quan trọng:

Ảnh hưởng của $\log(|c_{11}|)$:

Giá trị và dấu của $\log(|c_{11}|)$ quyết định **hướng thay đổi thông tin cho mỗi điểm ảnh** trong bản đồ đặc trưng đầu ra [9]:


- **Nếu $|c_{11}| > 1$:** Khi đó $\log(|c_{11}|) > 0$. Bộ lọc có xu hướng **khuếch đại tín hiệu và nhiễu** từ đầu vào, làm tăng entropy và tính đa dạng của thông tin. Nó có "tiềm năng" tạo ra các biểu diễn phong phú hơn [4].
- **Nếu $|c_{11}| < 1$:** Khi đó $\log(|c_{11}|) < 0$. Bộ lọc có xu hướng **giảm cường độ tín hiệu**, làm mịn (smoothing) và nén thông tin, dẫn đến giảm entropy [12]. Nó có "tiềm năng" lọc bỏ nhiễu và tập trung vào các đặc trưng nổi bật.
- **Nếu $|c_{11}| = 1$:** Khi đó $\log(|c_{11}|) = 0$. Về mặt lý thuyết, thành phần này không làm thay đổi entropy.

Ảnh hưởng của hệ số $(l - p + 1)(w - q + 1)$: Hệ số này phản ánh **tổng số lần bộ lọc được áp dụng** (số "cửa sổ" trượt) để tạo ra toàn bộ bản đồ đặc trưng đầu ra. Nó **khuếch đại hiệu ứng** của c_{11} lên toàn bộ bản đồ đặc trưng [9].

Kết luận: Việc tính toán được ΔH_{conv} một cách rõ ràng và hiệu quả cho phép chúng ta không chỉ theo dõi mà còn **chủ động hướng dẫn dòng thông tin** trong mạng [9]. Bằng cách thêm các hàm mất mát dựa trên ΔH (ví dụ: khuyến khích bảo toàn thông tin ở các lớp đầu và nén thông tin ở các lớp cuối), chúng ta có thể "dạy" cho mạng học các kiểu lan truyền entropy lý tưởng, từ đó giúp mạng:

1.6 Phương pháp Autoencoder

Mã hóa tự động (Autoencoder) là một mô hình học sâu deep learning được thiết kế để học biểu diễn nén của dữ liệu đầu vào mà không cần nhãn. Cấu trúc của một Autoencoder bao gồm hai phần chính: **bộ mã hóa (encoder)** và **bộ giải mã (decoder)**.



Hình 1.6.1: Kiến trúc Autoencoder

- **Bộ mã hóa (Encoder):** có nhiệm vụ biến đổi dữ liệu đầu vào x thành một biểu diễn có chiều thấp hơn, gọi là vector đặc trưng ẩn z . Quá trình này tương đương với việc trích chọn những đặc trưng quan trọng nhất của dữ liệu.
- **Bộ giải mã (Decoder):** tái tạo lại dữ liệu đầu vào $\hat{x}$ từ biểu diễn ẩn z , sao cho $\hat{x}$ gần giống với x ban đầu nhất có thể.

Mục tiêu huấn luyện của Autoencoder là tối thiểu hóa sai số giữa đầu vào và đầu ra tái tạo, thường được biểu diễn bởi hàm mất mát bình phương trung bình (Mean Squared Error):

$$L(x, \hat{x}) = \|x - \hat{x}\|^2$$


Trong các bài toán về thị giác máy tính, đặc biệt là xử lý ảnh, Autoencoder thường được triển khai dựa trên mạng nơ-ron tích chập. Khi đó, các lớp tích chập trong phần encoder giúp trích xuất đặc trưng không gian của ảnh, trong khi các lớp giải chập (deconvolution hoặc transpose convolution) trong phần decoder đảm nhiệm việc tái tạo ảnh từ các đặc trưng đã nén.

Nhờ khả năng học biểu diễn đặc trưng một cách không giám sát, Autoencoder đã trở thành nền tảng cho nhiều mô hình hiện đại trong thị giác máy tính, như siêu phân giải, khử nhiễu ảnh, và phát hiện bất thường. Khi được huấn luyện cùng các kiến trúc CNN sâu, Autoencoder

giúp mô hình trích chọn được các đặc trưng ngữ nghĩa và không gian mạnh mẽ hơn, cải thiện đáng kể chất lượng ảnh đầu ra.

1.7 Phương pháp GAN

Generative Adversarial Network (GAN) là một mô hình học sâu gồm hai thành phần chính: bộ sinh (Generator) và bộ phân biệt (Discriminator). Hai mô hình này được huấn luyện theo cơ chế đối kháng: Generator cố gắng tạo ra dữ liệu tổng hợp sao cho giống dữ liệu thật nhất có thể, trong khi Discriminator cố gắng phân biệt đâu là dữ liệu thật và đâu là dữ liệu do Generator sinh ra. Quá trình tối ưu ngược mục tiêu này tạo ra một vòng lặp cạnh tranh, giúp Generator dần học được phân phối của dữ liệu thật và sinh ra kết quả có chất lượng cao.



Hình 1.7.1: Kiến trúc GAN

Trong bài toán khử nhiễu ảnh, GAN thường được sử dụng như một mô hình sinh học nhằm tái tạo ảnh sạch từ ảnh bị nhiễu. Thay vì chỉ tối ưu theo hàm mất mát truyền thống như MSE hoặc MAE, GAN bổ sung thêm thành phần mất mát đối kháng (adversarial loss) để khuyến khích ảnh tái tạo có tính chân thực cao hơn. Điều này giúp mô hình phục hồi được các cấu trúc chi tiết, biên cạnh và hoa văn phức tạp mà các phương pháp khử nhiễu truyền thống thường làm mờ.

Cụ thể, Generator nhận đầu vào là ảnh nhiễu và sinh ra ảnh sạch dự đoán. Discriminator đánh giá xem ảnh đầu ra có giống ảnh thật hay không. Thông qua quá trình huấn luyện, Generator không chỉ cố gắng giảm sai số điểm ảnh mà còn học cách sinh ảnh giống thật theo đặc trưng

phân phối mà Discriminator học được từ dữ liệu sạch. Nhờ đó, các mô hình GAN được chứng minh là mang lại chất lượng thị giác tốt hơn so với các phương pháp dựa trên tối ưu điểm ảnh đơn thuần.

Về mặt tối ưu, hàm mất mát của GAN trong bài toán khử nhiễu ảnh thường được xây dựng dưới dạng hàm tổng hợp, bao gồm thành phần mất mát tái tạo theo điểm ảnh và thành phần mất mát đối kháng. Cụ thể, hàm mất mát đối kháng được định nghĩa như sau:

$$\mathcal{L}_{\text{adv}} = \mathbb{E}_{x \sim p_{\text{clean}}(x)} [\log D(x)] + \mathbb{E}_{y \sim p_{\text{noisy}}(y)} [\log(1 - D(G(y)))] \quad (1.3)$$

trong đó x là ảnh sạch, y là ảnh bị nhiễu, $G(y)$ là ảnh sạch dự đoán do bộ sinh tạo ra, và $D(\cdot)$ là xác suất mà bộ phân biệt gán cho đầu vào là ảnh thật.

Bên cạnh đó, để đảm bảo ảnh khôi phục giữ được độ chính xác theo điểm ảnh, một hàm mất mát tái tạo $\mathcal{L}_{\text{rec}}$ (chẳng hạn như MSE hoặc MAE) được sử dụng:

$$\mathcal{L}_{\text{rec}} = \mathbb{E}_{x,y} [\|G(y) - x\|] \quad (1.4)$$

Từ đó, hàm mất mát tổng của bộ sinh được xác định như sau:


$$\mathcal{L}_G = \lambda_{\text{rec}} \mathcal{L}_{\text{rec}} + \lambda_{\text{adv}} \mathcal{L}_{\text{adv}} \quad (1.5)$$

trong đó λ_{rec} và λ_{adv} là các hệ số trọng số dùng để cân bằng giữa độ chính xác tái tạo và chất lượng thị giác của ảnh đầu ra.

Việc kết hợp hàm mất mát tái tạo và hàm mất mát đối kháng cho phép mô hình GAN không chỉ giảm sai số theo điểm ảnh mà còn học được phân phối thống kê của ảnh sạch, từ đó tạo ra các ảnh khử nhiễu có cấu trúc tự nhiên và chất lượng cảm nhận cao hơn.

1.8 Phương pháp Flow-based

Flow-based(FB) là phương pháp sinh, học một ánh xạ khả nghịch giữa không gian ảnh và một phân phối xác suất đơn giản, thường là Gaussian chuẩn. Mô hình được cấu thành từ một chuỗi các phép biến đổi đảo ngược hoàn toàn, cho phép tính chính xác hàm likelihood của ảnh quan sát, đồng thời sinh mẫu trực tiếp.



Hình 1.8.1: Kiến trúc Flow based

Cụ thể, một ảnh chất lượng cao x được ánh xạ qua chuỗi biến đổi:

$$z = f_K \circ f_{K-1} \circ \cdots \circ f_1(x), \quad (1.6)$$

trong đó $f_k(\cdot)$ là phép biến đổi khả nghịch tại lớp thứ k của mô hình Flow, và h_{k-1} là biến trung gian đầu vào của lớp k , được định nghĩa bởi $h_0 = x$ và $h_k = f_k(h_{k-1})$. Sau K lớp biến đổi, ta thu được biến tiềm ẩn $z = h_K$, được giả định tuân theo phân phối Gaussian chuẩn $p(z)$.

Nhờ công thức biến đổi mật độ, hàm likelihood của ảnh x được tính chính xác như sau:

$$\log p(x) = \log p(z) + \sum_{k=1}^K \log \left| \det \left(\frac{\partial f_k(h_{k-1})}{\partial h_{k-1}} \right) \right|. \quad (1.7)$$

Trong đó, $\log p(z)$ đo lường mức độ phù hợp của biểu diễn tiềm ẩn z đối với phân phối chuẩn, còn các log-định thức Jacobian mô tả sự thay đổi thể tích không gian xác suất qua từng lớp biến đổi. Nhờ thiết kế các phép biến đổi có Jacobian tính toán hiệu quả, mô hình có thể được huấn luyện trực tiếp bằng phương pháp tối đa hóa likelihood.

Trong bài toán khôi phục ảnh, ảnh quan sát y (bị nhiễu, mờ hoặc giảm độ phân giải) được xem là kết quả của một phép suy biến từ ảnh gốc x . Khi mở rộng sang dạng có điều kiện, các phép biến đổi f_k được tham số hóa phụ thuộc vào y , cho phép mô hình học phân phối hậu nghiệm $p(x | y)$. Khi đó, quá trình khôi phục ảnh có thể được diễn giải như việc tìm hoặc lấy mẫu các nghiệm x có likelihood cao.

Đối với các bài toán như denoising, deblurring và đặc biệt là super-resolution, Flow-based models có khả năng sinh ra nhiều ảnh khôi phục

khác nhau nhưng đều phù hợp về mặt xác suất với cùng một ảnh quan sát. Nhờ vậy, mô hình không chỉ cải thiện chất lượng khôi phục mà còn mô hình hóa được độ bất định nội tại của bài toán.

Chương 2

Bài toán khử nhiễu và khử mờ cho ảnh phương tiện có biển số xe

2.1 Giới thiệu

Trong nhiều ứng dụng thực tế như hệ thống giám sát giao thông, nhận dạng biển số tự động và các hệ thống an ninh, chất lượng ảnh thu được thường bị suy giảm do nhiều nguyên nhân: điều kiện ánh sáng kém, chuyển động nhanh của phương tiện, rung lắc camera, hoặc giới hạn của cảm biến. Những suy giảm phổ biến nhất là nhiễu và mờ. Khử nhiễu và khử mờ là các bước tiền xử lý then chốt để phục hồi hình ảnh có độ nét và độ tương phản cao, từ đó cải thiện hiệu suất các tác vụ hạ tầng như nhận diện ký tự (OCR) trên biển số.

Tính cần thiết của bài toán Biển số xe là vùng nhỏ, chứa thông tin nhạy cảm và cần độ chính xác cao khi nhận diện. Một biển số bị mờ hoặc nhiễu có thể khiến hệ thống ANPR sai lệch, dẫn đến hậu quả trong quản lý giao thông, xử lý vi phạm, hoặc điều tra an ninh. Do đó, phát triển phương pháp khử nhiễu và khử mờ hiệu quả cho ảnh phương tiện có biển số là cần thiết để:

- Tăng tỉ lệ nhận diện ký tự đúng.
- Giảm sai số trong các hệ thống theo dõi và truy vết.
- Thu nhỏ kích thước mô hình khi triển khai trên thiết bị nhúng mà vẫn giữ được chất lượng phục hồi.

2.2 Phát biểu bài toán

Cho một ảnh quan sát Y chứa phương tiện và vùng biển số bị suy giảm do nhiễu và/hoặc mờ, mục tiêu là tìm một ảnh ước lượng $\hat{X}$ gần với ảnh nguyên gốc X (chưa bị suy giảm). Mô hình tổng quát có thể được viết:

$$Y = K * X + N, \quad (2.1)$$

trong đó K là hạt nhân làm mờ (blur kernel), $*$ biểu diễn phép nhân chập, và N là thành phần nhiễu (ví dụ: Gaussian noise, Poisson noise, hoặc nhiễu phụ thuộc cảm biến). Nhiệm vụ khử mờ và khử nhiễu là ước lượng $\hat{X}$ và — nếu cần thiết — ước lượng K từ Y .

Đặc điểm và thách thức Bài toán khử nhiễu, khử mờ cho ảnh phương tiện có biển số có những thách thức đặc thù:

- **Kích thước vùng quan tâm nhỏ:** Biển số chiếm phần nhỏ trong ảnh toàn cảnh, do đó phương pháp phải bảo toàn chi tiết ở vùng biển số mà không làm mịn quá mức.
- **Mờ chuyển động và mờ do khẩu độ:** Mờ có thể do chuyển động nhanh của xe hoặc do sai nét — hai loại mờ này có đặc tính khác nhau và cần xử lý khác biệt.
- **Nhiều phi chuẩn và điều kiện ánh sáng thay đổi:** Nhiễu thực tế không luôn tuân theo phân phối Gaussian chuẩn; ngoài ra bóng đổ, phản xạ, và điều kiện ánh sáng yếu làm tăng độ khó.
- **Yêu cầu thời gian thực và tài nguyên giới hạn:** Ứng dụng triển khai trên camera giao thông hoặc thiết bị nhúng yêu cầu thuật toán có độ trễ thấp và tiêu thụ bộ nhớ/điện năng nhỏ.
- **Đòi hỏi giữ chi tiết ký tự:** Việc khử nhiễu/mờ phải bảo toàn các cạnh sắc và nét chữ để không làm ảnh hưởng đến hiệu suất OCR.

Mục tiêu nghiên cứu Trong bối cảnh giới thiệu này, mục tiêu tổng quát của nghiên cứu có thể tóm tắt như sau:

1. Đề xuất hoặc lựa chọn phương pháp khử nhiễu và khử mờ hiệu quả cho ảnh phương tiện, tập trung vào việc bảo toàn chi tiết vùng biển số.
2. Tối ưu hóa mô hình về số tham số và chi phí tính toán để phù hợp triển khai trên thiết bị thực tế.

- Đánh giá hiệu quả bằng các chỉ số ảnh kỹ thuật (PSNR, SSIM) và tỷ lệ nhận diện biển số sau xử lý.

Chỉ số đánh giá Hiệu quả phương pháp thường được đánh giá bằng:

- **PSNR** (Peak Signal-to-Noise Ratio), **SSIM** (Structural Similarity Index), **NMSE** (Normalized Mean Squared Error) cho chất lượng phục hồi tổng quát.
- **Thời gian xử lý và kích thước mô hình** khi triển khai.

2.3 Khoảng trống nghiên cứu

Trong phần này, em tóm tắt các khoảng trống nghiên cứu chính liên quan đến ba nhóm phương pháp phổ biến được đề cập trong tài liệu: AE, GAN và FB.

Autoencoder (AE): AE thường được sử dụng trong tăng cường ảnh giao thông nhờ thiết kế gọn nhẹ, phù hợp với các hệ thống giám sát hạn chế về tài nguyên. Tuy nhiên, các bộ mã hóa nông thường chỉ trích xuất được các đặc trưng cấp thấp và thất bại trong việc khôi phục các cấu trúc trung và cao cấp — vốn là yếu tố then chốt để tái tạo chi tiết tinh vi [13, 14]. Điều này khiến AE có xu hướng làm mờ các kết cấu nhỏ, đặc biệt là khi đối tượng mục tiêu như biển số xe chỉ chiếm một vùng nhỏ trong ảnh.

Generative Adversarial Network (GAN): GAN giúp cải thiện độ chân thực cảm nhận (perceptual realism) với các cạnh sắc nét và kết cấu tự nhiên hơn. Tuy nhiên, chúng thường làm biến dạng độ trung thực ở mức pixel và có thể gây ra hiện tượng “ảo ảnh” tạo ra các con số giả trên biển số xe. Điều này làm giảm độ tin cậy trong các ứng dụng giao thông, nơi việc khôi phục chính xác các chi tiết như biển số và vạch kẻ đường là bắt buộc [7].

Flow-Based (FB): Các mô hình FB bảo toàn độ chính xác ở mức pixel bằng cách tối ưu hóa trực tiếp hàm log-likelihood, cho phép ánh xạ khả nghịch để giữ lại các chi tiết vi mô [2, 6]. Dù vậy, độ phức tạp tính toán cao và mức tiêu thụ bộ nhớ lớn khiến chúng khó triển khai thực tế trên các thiết bị biên (edge devices). Hiện nay, vẫn tồn tại một khoảng trống nghiên cứu trong việc phát triển các kiến trúc có khả năng cân bằng giữa hiệu suất tính toán và khả năng bảo toàn chi tiết chính xác cho tăng cường ảnh giao thông.

Tổng kết: Khoảng trống nghiên cứu chính là thiết kế mô hình nhẹ, thời gian thực nhưng vẫn bảo toàn chi tiết


Chương 3

Phương pháp VRAE: Vertical Residual Autoencoder

Trong chương này, em trình bày chi tiết phương pháp VRAE (Vertical Residual Autoencoder), một kiến trúc nhẹ chuyên dụng cho bài toán khử nhiễu và khử mờ biến số xe. Mục tiêu của VRAE là duy trì fidelity (PSNR/SSIM), bảo toàn chi tiết vi mô, đồng thời đạt hiệu năng tính toán phù hợp cho ứng dụng thời gian thực trên ảnh có phần vùng quan tâm nhỏ.

3.1 Tổng quan kiến trúc

VRAE là một biến thể của Autoencoder với cấu trúc encoder–decoder chuẩn nhưng mở rộng bằng các khối residual theo chiều dọc và khối hỗ trợ. Encoder sử dụng backbone dựa trên ResNet-50 (giữ cân bằng giữa năng lực biểu diễn và chi phí tính toán), trong khi decoder phục hồi ảnh sạch thông qua các lớp tích chập ngược (deconvolution).



Hình 3.1.1: Kiến trúc phương pháp VRAE

3.1.1 Khối chính (Main Block)

Khối chính là thành phần cốt lõi giúp bảo toàn và biến đổi thông tin theo trục dọc của kiến trúc. Trong thiết kế này, mỗi khối mã hóa chính E_i được hiện thực hóa dựa trên các giai đoạn của kiến trúc **ResNet-50**. Các đặc điểm quan trọng bao gồm:

- **Cấu trúc Bottleneck:** Mỗi khối sử dụng thiết kế bottleneck gồm ba lớp convolution: lớp 1×1 để giảm chiều dữ liệu, lớp 3×3 để xử lý không gian và một lớp 1×1 khác để khôi phục lại số kênh ban đầu.
- **Kết nối tắt (Skip-connection):** Tương tự như mạng dư (Residual Networks), một kết nối tắt được thêm vào đầu ra của khối, giúp cải thiện dòng gradient và giảm thiểu vấn đề triệt tiêu gradient khi huấn luyện mạng sâu.
- **Cơ chế hội tụ đặc trưng:** Tại mỗi giai đoạn, đặc trưng từ luồng chính và luồng bổ trợ được kết hợp bằng phép cộng phần tử trước khi đưa vào khối mã hóa tiếp theo:

$$\mathbf{x}_i = E_i(\mathbf{x}_{i-1} + \mathbf{x}'_{i-1}), \quad i = 2, \dots, 5 \quad (3.1)$$

Trong đó $\mathbf{x}_{i-1}$ là đầu ra của khối chính trước đó và $\mathbf{x}'_{i-1}$ là đầu ra từ khối bổ trợ tương ứng.

3.1.2 Khối bổ trợ (Auxiliary Block)

Để tăng cường khả năng giữ lại thông tin cục bộ và ngữ cảnh từ ảnh đầu vào, VRAE tích hợp một lộ trình bổ trợ $\{E'_i\}$ đóng vai trò như một *mô-đun nhúng đặc trưng* (feature embedding module).

- **Cấu trúc tinh gọn:** Các khối bổ trợ tuân theo cấu trúc **Conv-Norm-Activation** nông và có thể tích hợp thêm các lớp pooling để tóm tắt ngữ cảnh toàn cục của ảnh đầu vào x :

$$\mathbf{x}'_i = E'_i(\mathbf{x}), \quad i = 1, \dots, 5 \quad (3.2)$$

- **Tích hợp đa cấp:** Các đặc trưng này được tiêm (inject) lũy tiến vào các tầng tương ứng của khối chính thông qua phép cộng phần tử. Đây là giải pháp thay thế hiệu quả về mặt tham số so với phép ghép nối (concatenation).
- **Vai trò:** Cơ chế này cho phép mô hình làm giàu các biểu diễn ở mức

thấp (low-level) và mức trung bình (mid-level) bằng các manh mối hỗ trợ trực tiếp từ ảnh gốc, thay vì chỉ dựa vào thông tin đã bị nén qua nhiều lớp.

3.1.3 Bộ giải mã (Decoder)

Bộ giải mã D thực hiện nhiệm vụ khôi phục đầu ra $\hat{x}$ từ biểu diễn nén $\mathbf{x}_N$ thông qua một chuỗi các tầng *transposed convolutional layers* kết hợp với hàm kích hoạt *ReLU*. Quá trình này thực hiện lấy mẫu lên (upsampling) các bản đồ đặc trưng một cách lũy tiến để khôi phục độ phân giải không gian ban đầu:

$$\mathbf{y}_k = \text{ReLU}(\text{ConvTranspose2d}_k(\mathbf{y}_{k-1})), \quad k = 1, \dots, 5, \quad \mathbf{y}_0 = \mathbf{x}_N, \quad \mathbf{y}_K = \hat{\mathbf{x}} \quad (3.3)$$

Mô hình được huấn luyện bằng cách tối ưu hóa hàm mất mát Sai số bình phương trung bình (*Mean Squared Error* - MSE):

$$\mathcal{L}_{\text{MSE}} = \frac{1}{BCHW} \sum_{b=1}^B \sum_{c=1}^C \sum_{i=1}^H \sum_{j=1}^W (\hat{x}_{b,c,i,j} - x_{b,c,i,j})^2 \quad (3.4)$$

Hàm mất mát này tính toán giá trị trung bình của bình phương sai số tái cấu trúc trên toàn bộ lô (batch), tất cả các kênh màu và các điểm ảnh, giúp mô hình học cách tái tạo chính xác các chi tiết từ ảnh gốc.

3.2 Chuẩn bị dữ liệu

Dữ liệu được sử dụng trong nghiên cứu này được trích xuất từ tập dữ liệu CCPP, bao gồm 3,036 hình ảnh phương tiện giao thông độ phân giải cao đã được thay đổi kích thước về 256×256 pixels. Quy trình chuẩn bị và xử lý dữ liệu được thực hiện như sau:

- **Phân chia tập dữ liệu:** Tập dữ liệu được chia thành các tập huấn luyện (training), kiểm định (validation) và kiểm thử (test) theo tỷ lệ tương ứng là 70%–15%–15%.
- **Tăng cường dữ liệu (Data Augmentation):** Các kỹ thuật tăng cường dữ liệu, bao gồm xoay ảnh, chỉ được áp dụng cho tập huấn luyện, giúp tăng quy mô tập dữ liệu này lên thành 7,000 hình ảnh.
- **Mô phỏng dữ liệu chất lượng thấp:** Để mô phỏng các thước phim giám sát chất lượng thấp, các đầu vào độ phân giải thấp được tạo

ra bằng cách:

- Thêm nhiễu rời rạc (các giá trị trong đoạn $[0, 9]$ được nhân với hệ số 0.1).
- Áp dụng lặp lại 10 lần bộ lọc *average pooling* kích thước 3×3 .
- **Đặc điểm suy giảm:** Quy trình suy giảm này có những nét tương đồng với các phương pháp suy giảm tổng hợp được sử dụng trong SRMD, nơi các tổ hợp của làm mờ (blurring) và nhiễu (noise) được sử dụng để mô phỏng nhiều điều kiện độ phân giải thấp khác nhau.

3.3 Lựa chọn cấu hình kiến trúc

Để đảm bảo quá trình đánh giá được khách quan và nhất quán, em chi tiết hóa cấu hình kiến trúc cho các mô hình cơ sở dựa trên nền tảng của mạng ResNet50. Việc sử dụng các tầng trích xuất đặc trưng tiêu chuẩn giúp kiểm soát dung lượng mô hình và tập trung vào hiệu quả của từng phương pháp tiếp cận.

Bộ tự mã hóa tự động:

Kiến trúc Auto-Encoder tiêu chuẩn được xây dựng dựa trên cấu trúc đối xứng giữa bộ mã hóa (encoder) và bộ giải mã (decoder). Trong đó, bộ mã hóa tận dụng toàn bộ sức mạnh trích xuất đặc trưng phân cấp từ **5 giai đoạn đầu (Stage 1 đến Stage 5)** của mạng ResNet50. Các đặc trưng ở cấp độ ngữ nghĩa cao này sau đó được đưa qua bộ giải mã để tái cấu trúc lại hình ảnh đầu vào thông qua các lớp tích chập chuyển vị.

Mô hình dựa trên luồng:

Đối với phương pháp dựa trên luồng, em sử dụng **4 giai đoạn đầu** của ResNet50 làm khung cho bộ mã hóa. Cấu hình này nhằm cân bằng giữa tính nghịch đảo chính xác (exact invertibility) của các tầng flow và khả năng bảo toàn thông tin không gian chi tiết từ các tầng trung gian của ResNet, giúp duy trì các đặc điểm tinh vi của phương tiện trong không gian tiềm ẩn.

Mạng đối nghịch giả tạo:

Mô hình GAN được thiết kế dựa trên khung tham chiếu của các nghiên cứu phục hồi hình ảnh tiên phong, cụ thể:

- **Bộ sinh (Generator):** Tương tự như cấu hình của mô hình FB, phần mã hóa của bộ sinh sử dụng **4 giai đoạn đầu** của ResNet50. Điều này đảm bảo bộ sinh có khả năng hiểu cấu trúc phương tiện mạnh mẽ trước khi thực hiện quá trình lấy mẫu lên (upsampling).

- **Bộ phân biệt (Discriminator):** Em kế thừa kiến trúc bộ phân biệt từ mô hình SRGAN. Kiến trúc này sử dụng một chuỗi các lớp tích chập với số lượng bộ lọc tăng dần và tích chập sai bước (strided convolutions) để phân biệt hiệu quả giữa hình ảnh phục hồi và hình ảnh thực tế (ground-truth).

Tính nhất quán trong thực nghiệm:

Để đảm bảo so sánh công bằng, các khối mã hóa và giải mã chính trong cả ba mô hình AE, FB và GAN đều được thiết kế đồng nhất với phương pháp đề xuất của em. Sự thống nhất này giúp loại bỏ các tác động nhiễu do khác biệt về số lượng tham số, từ đó làm nổi bật ưu điểm của cơ chế học mà em tập trung nghiên cứu.

Lựa chọn hàm mất mát:

Việc lựa chọn hàm mất mát đóng vai trò quan trọng trong quá trình huấn luyện mô hình, ảnh hưởng trực tiếp đến chất lượng và tính ổn định của kết quả tái tạo. Trong nghiên cứu này, các mô hình được chia thành hai nhóm chính dựa trên đặc điểm kiến trúc và mục tiêu tối ưu.

Đối với các phương pháp **Autoencoder (AE)**, **Flow-Based (FB)** và **Vertical Residual Autoencoder (VRAE)**, mục tiêu chính là tái tạo ảnh đầu ra gần với ảnh gốc về mặt giá trị điểm ảnh. Do đó, hàm mất mát **Mean Squared Error (MSE)** được sử dụng để đo lường sai khác giữa ảnh tái tạo $\hat{x}$ và ảnh gốc x :

$$\mathcal{L}_{\text{MSE}} = \|\hat{x} - x\|_2^2. \quad (3.5)$$

Hàm mất mát này khuyến khích mô hình học được ánh xạ tối ưu theo nghĩa bình phương sai số, đồng thời đảm bảo quá trình huấn luyện ổn định và hội tụ.

Đối với phương pháp **Generative Adversarial Network (GAN)**, để khắc phục hiện tượng ảnh tái tạo bị làm mịn quá mức khi chỉ sử dụng MSE, một hàm mất mát kết hợp được áp dụng. Cụ thể, hàm mất mát của bộ sinh (Generator) bao gồm hai thành phần: MSE loss ở mức điểm ảnh và adversarial loss dựa trên Binary Cross-Entropy (BCE). Tổng hàm mất mát của Generator được xác định như sau:

$$\mathcal{L}_{\text{GEN}} = \mathcal{L}_{\text{MSE}} + \alpha \cdot \mathcal{L}_{\text{BCE}}, \quad (3.6)$$

trong đó α là một hệ số vô hướng nhỏ nhằm cân bằng đóng góp của adversarial loss, với $\alpha = 10^{-3}$ theo thiết lập ban đầu được đề xuất trong [8]. Thành phần adversarial loss giúp mô hình sinh ra các ảnh có tính chân thực cao hơn về mặt cảm nhận thị giác, trong khi MSE vẫn đảm bảo sự gần đúng với ảnh gốc.

Cấu hình quá trình huấn luyện:

Tất cả các mô hình trong nghiên cứu này được huấn luyện bằng thuật toán tối ưu Adam với tốc độ học ban đầu là 1×10^{-4} . Kích thước batch được thiết lập là 16. Mỗi mô hình được huấn luyện trong 100 epochs trên GPU NVIDIA RTX 4070.

Chương 4

Kết quả và thảo luận

Trong chương này, em trình bày các kết quả thực nghiệm đạt được của phương pháp VRAE so với các phương pháp cơ sở (AE, GAN, FB). Các kết quả được đánh giá thông qua cả hai khía cạnh: định lượng (các chỉ số đo lường) và phân tích sâu về cơ chế hoạt động của mô hình.

4.1 Đánh giá định lượng

Hiệu suất của phương pháp đề xuất VRAE được so sánh với các mô hình GAN, FB và các biến thể của Autoencoder (AE) với các độ sâu khác nhau (từ 2 đến 5 khối). Kết quả chi tiết được tổng hợp trong Bảng 4.1.1.

Bảng 4.1.1: So sánh định lượng giữa GAN, FB, AE và phương pháp VRAE đề xuất trên tập kiểm tra (Test set).

Mô hình	PSNR (dB) $\uparrow$	NMSE $\downarrow$	SSIM $\uparrow$	Tham số	FPS
GAN (Gen)	28,743	0,006	0,842	14,59M	188
FB (Gen)	27,093	0,008	0,831	25,87M	35
AE2	27,787	0,007	0,840	0,375M	411
AE3	26,159	0,011	0,802	2,77M	289
AE4	29,404	0,005	0,864	14,59M	189
AE5	27,243	0,008	0,793	48,43M	119
VRAE2	30,319	0,004	0,884	0,376M	399
VRAE3	31,052	0,003	0,898	2,78M	194
VRAE4	30,246	0,004	0,880	14,61M	90
VRAE5	30,032	0,003	0,860	48,48M	45

Dựa trên kết quả ở Bảng 4.1.1, có thể đưa ra các nhận xét sau:


- **Độ chính xác tái tạo:** Mô hình **VRAE3** đạt kết quả cao nhất ở cả ba chỉ số PSNR (31,052 dB), SSIM (0,898) và có NMSE thấp nhất

(0,003). Điều này khẳng định hiệu quả của cơ chế kết nối dư dặc (Vertical Residual) trong việc khôi phục chi tiết ảnh.

- **So sánh với AE truyền thống:** Khi so sánh ở cùng một độ sâu, VRAE luôn vượt trội hơn hẳn so với AE. Cụ thể, VRAE giúp cải thiện PSNR khoảng 20
- **Hiệu năng tính toán:** Mô hình **VRAE2** cho thấy sự cân bằng tuyệt vời giữa chất lượng và tốc độ khi đạt 399 FPS, rất phù hợp cho các ứng dụng giám sát giao thông thời gian thực.

4.2 Phân tích bảo toàn nội dung thông tin

Để hiểu rõ hơn tại sao VRAE lại hoạt động hiệu quả, nghiên cứu thực hiện phân tích sự thay đổi Entropy giữa các lớp của bộ mã hóa. Entropy được dùng để đo lường lượng thông tin được giữ lại trong quá trình trích xuất đặc trưng.



Hình 4.2.1: Sự thay đổi Entropy trung bình qua các lớp mã hóa của AE và VRAE.


Kết quả phân tích cho thấy:

- **Giai đoạn đầu:** Các mô hình VRAE bắt đầu với mức độ thay đổi Entropy cao hơn so với AE thông thường, đặc biệt là ở lớp mã hóa đầu tiên. Điều này chứng tỏ VRAE bảo toàn được nhiều đặc trưng thô và chi tiết vi mô hơn ngay từ đầu.
- **Sự ổn định:** Tốc độ giảm Entropy trong VRAE diễn ra mượt mà và nhất quán hơn so với AE. Ví dụ, VRAE3 giảm dần từ -1,5 xuống -3,7, trong khi AE3 giảm đột ngột từ -6,3 xuống -3,5. Sự thay đổi

dần dần này giúp tránh hiện tượng ”sụp đổ thông tin”(information collapse) quá sớm ở các tầng nông.

4.3 Phân tích sự đánh đổi (Trade-offs)

Thông qua phân tích mặt tiền Pareto (Pareto Front) giữa chất lượng tái tạo (PSNR/SSIM) và tốc độ suy luận (FPS), chúng em nhận thấy:



Hình 4.3.1: Trực quan hóa sự đánh đổi giữa hiệu suất tái tạo (NMSE, PSNR, SSIM) và tốc độ suy luận (FPS) thông qua mặt tiền Pareto.

Chúng em nhận thấy:

- Các biến thể VRAE (đặc biệt là VRAE2 và VRAE3) nằm trên đường biên tối ưu, thể hiện sự kết hợp tốt nhất giữa độ chính xác và hiệu năng.
- Ngược lại, các mô hình GAN và FB có số lượng tham số lớn nhưng hiệu quả tái tạo và tốc độ suy luận đều thấp hơn so với VRAE trong bài toán cụ thể này.

4.4 Hướng phát triển trong tương lai

Dựa trên những kết quả đạt được và các hạn chế còn tồn tại, nghiên cứu này có thể được mở rộng theo các hướng sau trong tương lai:

- **Tối ưu hóa và nén mô hình:** Nghiên cứu các kỹ thuật nén mô hình như cắt tỉa (pruning), lượng tử hóa (quantization) và chưng cất tri thức (knowledge distillation). Các phương pháp này sẽ giúp giảm đáng kể dung lượng và tăng tốc độ suy luận, tạo điều kiện thuận lợi cho việc triển khai VRAE trên các thiết bị nhúng và hệ thống giám sát giao thông thực tế.
- **Kiến trúc độ sâu thích ứng:** Phát triển các khối mã hóa có khả năng tự động điều chỉnh độ sâu (adaptive-depth) tùy thuộc vào độ

phức tạp của ảnh đầu vào, từ đó tiết kiệm tài nguyên tính toán cho những trường hợp ảnh ít nhiễu.

- **Khôi phục video thời gian thực:** Mở rộng phương pháp VRAE từ khôi phục ảnh tĩnh sang khôi phục luồng video, tận dụng thông tin liên quan giữa các khung hình kề nhau để tăng cường độ ổn định và chính xác của quá trình xử lý.
- **Đánh giá đa dạng:** Thực nghiệm mô hình trên nhiều bộ dữ liệu biến số xe khác nhau (như các loại biển số quốc tế, biển số xe máy) và trong các điều kiện thời tiết khắc nghiệt hơn (mưa lớn, sương mù dày đặc) để nâng cao tính tổng quát của nghiên cứu.

4.5 Kết luận

Trong chương này, em đã trình bày các kết quả thực nghiệm của phương pháp VRAE so với các phương pháp cơ sở (AE, GAN, FB). Kết quả cho thấy:

- **Hiệu quả vượt trội:** VRAE3 đạt PSNR cao nhất (31,052 dB), SSIM tốt nhất (0,898) và NMSE thấp nhất (0,003), vượt trội hơn hẳn so với các phương pháp cơ sở.
- **Cân bằng hiệu suất:** VRAE2 cho thấy sự cân bằng tuyệt vời giữa chất lượng và tốc độ (399 FPS), phù hợp cho ứng dụng thời gian thực.
- **Bảo toàn thông tin:** Phân tích Entropy chứng minh VRAE bảo toàn được nhiều đặc trưng chi tiết hơn so với AE thông thường.
- **Tối ưu Pareto:** Các biến thể VRAE nằm trên đường biên tối ưu, thể hiện sự kết hợp tốt nhất giữa độ chính xác và hiệu năng.
- **Công bố khoa học:** Kết quả nghiên cứu của đề án này đã được chấp nhận đăng và báo cáo tại Hội nghị Quốc tế về Công nghệ Thông tin và Truyền thông lần thứ 14 (SOICT 2025), khẳng định giá trị khoa học và tính ứng dụng thực tiễn của phương pháp VRAE.

Minh chứng bài báo khoa học

Dưới đây là các minh chứng về kết quả nghiên cứu của đồ án:



Hình 4.5.1: Giấy chứng nhận tham dự và trình bày tại SOICT 2025

Tài liệu tham khảo

- [1] T. M. Cover and J. A. Thomas. *Elements of Information Theory*. John Wiley & Sons, 2006.
- [2] L. Dinh, J. Sohl-Dickstein, and S. Bengio. Density estimation using real nvp. In *International Conference on Learning Representations (ICLR)*, 2017.
- [3] D. Erdogmus, K. E. Hild, and J. C. Principe. Online entropy manipulation: Stochastic information gradient. *IEEE Signal Processing Letters*, 10(8):242–245, 2003.
- [4] M. Gabriele, A. Manoel, C. Luneau, N. Macris, F. Krzakala, and L. Zdeborova. Entropy and mutual information in models of deep neural networks. In *Advances in Neural Information Processing Systems*, volume 31, 2018.
- [5] K. He, X. Zhang, S. Ren, and J. Sun. Deep residual learning for image recognition. In *Proceedings of the IEEE CVPR*, 2016.
- [6] D. P. Kingma and P. Dhariwal. Glow: Generative flow with invertible 1x1 convolutions. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2018.
- [7] O. Kupyn, V. Budzan, M. Mykhailych, D. Mishkin, and J. Matas. Deblurgan: Blind motion deblurring using conditional adversarial networks. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR) Workshops*, 2018.
- [8] C. Ledig, L. Theis, F. Huszár, J. Caballero, A. Cunningham, A. Acosta, A. Aitken, A. Tejani, J. Totz, Z. Wang, and W. Shi. Photo-realistic single image super-resolution using a generative adversarial network. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2017.
- [9] M. J. Meni, R. T. White, M. L. Mayo, and K. R. Pilkievicz. Entropy-based guidance of deep neural networks for accelerated convergence and improved performance. *Information Sciences*, 681, 2023.

- [10] J. C. Principe, D. Xu, Q. Zhao, and J. W. Fisher. Learning from examples with information theoretic criteria. *Journal of VLSI Signal Processing Systems for Signal, Image, and Video Technology*, 26(1):61–77, 2000.
- [11] C. E. Shannon. A mathematical theory of communication. *The Bell System Technical Journal*, 27(3):379–423, 1948.
- [12] N. Tishby, F. C. Pereira, and W. Bialek. The information bottleneck method. In *Proceedings of the 37th Annual Allerton Conference on Communication, Control, and Computing*, pages 368–377, 1999.
- [13] P. Vincent, H. Larochelle, Y. Bengio, and P.-A. Manzagol. Extracting and composing robust features with denoising autoencoders. In *Proceedings of the 25th International Conference on Machine Learning (ICML)*, pages 1096–1103, 2008.
- [14] K. Zhang, W. Zuo, Y. Chen, D. Meng, and L. Zhang. Beyond a gaussian denoiser: Residual learning of deep cnn for image denoising. *IEEE Transactions on Image Processing*, 26(7):3142–3155, 2017.